

学校代码：10255

学号：2121087

免疫卷积神经网络并行优化及其嵌入式系统应用

**PARALLEL OPTIMIZATION OF IMMUNE COVOLUTION  
NERUAL NETWORK AND ITS APPLICATION WITH  
EMBEDDED SYSTEM**

专业：控制科学与工程

作者：郭吉政

指导老师：龚涛

答辩日期：2015/1/19

# 东华大学学位论文原创性声明

本人郑重声明：我恪守学术道德，崇尚严谨学风。所呈交的学位论文，是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已明确注明和引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的作品及成果的内容。论文为本人亲自撰写，我对所写的内容负责，并完全意识到本声明的法律结果由本人承担。

学位论文作者签名：

日期：            年    月    日

# 东华大学学位论文版权使用授权书

学位论文作者完全了解学校有关保留、使用学位论文的规定，同意学校保留并向国家有关部门或机构送交论文的复印件和电子版，允许论文被查阅或借阅。本人授权东华大学可以将本学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存和汇编本学位论文。

保密 ☐，在 \_\_\_\_ 年解密后适用本版权书。

本学位论文属于

不保密 ☐。

学位论文作者签名：

指导教师签名：

日期：      年    月    日

日期：      年    月    日

## 免疫卷积神经网络并行优化及其嵌入式系统应用

### 摘要

当前图像识别系统应用的领域越来越广泛,从工业智能监控一直到汽车无人驾驶乃至太空探索都应用到了图像识别系统。卷积神经网络是将人工神经网络与深度学习技术相结合而产生的一个新型人工神经网络分支方法,具有局部感知区域、层次化结构、特征提取和分类过程相结合的全局训练等特点,在图像识别领域获得了广泛的应用。进化计算,人工神经网络和人工免疫系统在学习方面存在一些共性,但是又有各自的特点。免疫系统的适应、学习和记忆能力不仅适用于优化领域,也适合开发用于机器学习的人工免疫系统,虽然现在已经出现了很多学习算法和理论,但没有一种是完善和万能的,目前只能互补。

本文通过对国内外有关卷积神经网络,人工免疫系统,嵌入式图像处理系统和 GPU 加速并行计算的发展现状和研究成果进行整理和总结。并且对人工免疫网络和卷积神经网络的算法和结构进行详细阐述,通过人工免疫系统与卷积神经网络结合,提出了一种新的图像识别算法,免疫卷积神经网络算法,最后通过采用 NVIDIA 公司 GPU 加速并行计算,提高识别速度,满足当前嵌入式设备实时性需求,并且搭建嵌入式图像实时识别系统。

本文主要研究内容包括以下几个方面:

1. 对卷积神经网络的网络结构以及参数进行分析,针对卷积神经网络网络结构复杂,训练耗时长,容易出现过拟合并且误分类高等缺点,本文基于人工免疫算法在模式识别的优点用于改进卷积神经网络算法,提出了一种免疫卷积神经网络算法,该算法综合了网络节点的定位与参数的调整以及能够动态调节基函数的平滑因子。

2. 采用 NVIDIA 公司最新推出的 cuDNN 深度神经网络库，用来加速机器学习，使得该免疫卷积神经网络模型可以用到对实时性要求很高的嵌入式平台。

3. 完成多功能图像识别系统 ARM+linux 平台的搭建，包括 linux 操作系统的裁剪、各硬件模块的驱动部分的编写、以及传感器信号的预处理，实现免疫卷积神经网络并行优化算法在嵌入式图像识别的应用研究。

**关键词：**卷积神经网络，人工免疫系统，机器学习，嵌入式系统，GPU 加速

# PARALLEL OPTIMIZATION OF IMMUNE COVOLUTION NERUAL NETWORK AND ITS APPLICATION WITH EMBEDDED SYSTEM

## ABSTRACT

Nowadays, image recognition technologies have been widely used in many fields, including unmanned vehicles, intelligent monitoring and even outer space exploring. Convolution neural network (CNN) is a technology that combines the artificial neural network (ANN) and the deep learning method. It is characterized by local receptive filed, hierarchical structure, global learning for feature extraction and classification and has been applied to many image recognition fields. Evolutionary computation, artificial neural networks and artificial immune system have many things in common , but also have their own characteristics. Adaptation, learning and memorizing ability of the immune system can not only be applied to the field of optimization, but also machine learning, such as artificial immune system. Although there are a lot of learning theories and methods, none is perfect and omnipotent. They just complement each other.

In this work, the development of artificial neural networks, convolution neural network,the embedded image processing system and GPU accelerated parallel processing and the latest research results at home and abroad were reviewed and summarized. The concepts and algorithms of artificial neural networks and classical convolution neural network were briefly introduced. Finally, an embedded real-time image recognition system was established, which adopted the theories of artificial immune system and convolution neural network,called I-CNN. The algorithm was implemented on GPUs, which efficiently accelerated its speed.

The main work is designed as follows:

1. Analyze the network structure and parameters of the convolution neural network, the complex network structure, the long time training, the over fitting and classification accuracy is not higher,in order to overcome this difficulty, A immune convolution neural network algorithm based on the advantages of artificial immune algorithm was established, The proposed algorithm merges the positioning and parameter adjustment of network nodes as well as the parameter tuning of basis functions.

2. Use the cuDNN depth neural network library from NVIDIA to accelerate the process for machine learning, so that deep neural network model can be used for real-time convolution in embedded platforms.

3. Complete the setting up of image recognition system based on ARM + Linux . This includes the tailoring of Linux operating system, the driver module of hardware, and the pre-processing of the signals from the sensors, The parallel optimization of immune convolution neural network and the application in embedded image recognition system.

Jizheng Guo ( Control Science and Engineering )

Supervised by Professor Gong Tao

**KEY WORDS:** convolution neural networks, artificial immune system, machine learning, embedded systems, gpu acceleration



## 目录

|                                   |     |
|-----------------------------------|-----|
| 摘要.....                           | I   |
| ABSTRACT.....                     | III |
| 目录.....                           | V   |
| 第一章 绪论.....                       | 1   |
| 1.1 课题研究背景和意义.....                | 1   |
| 1.2 国内外研究现状.....                  | 2   |
| 1.2.1 卷积神经网络研究现状.....             | 3   |
| 1.2.2 人工免疫系统研究现状.....             | 3   |
| 1.2.3 嵌入式图像处理系统发展及现状.....         | 4   |
| 1.2.4 GPU 加速并行计算研究现状.....         | 5   |
| 1.3 论文的创新.....                    | 5   |
| 1.4 本文的主要工作.....                  | 6   |
| 第二章 免疫卷积神经网络结构与算法.....            | 9   |
| 2.1 人工免疫网络概述.....                 | 9   |
| 2.1.1 免疫系统模式识别.....               | 9   |
| 2.1.2 免疫分类算法研究.....               | 10  |
| 2.2 人工神经网络.....                   | 11  |
| 2.2.1 神经网络模型.....                 | 11  |
| 2.2.2 反向传导算法.....                 | 11  |
| 2.3 卷积神经网络.....                   | 14  |
| 2.3.1 卷积神经网络的架构.....              | 14  |
| 2.3.2 径向基网络.....                  | 15  |
| 2.3.3 卷积网络的训练过程.....              | 18  |
| 2.3.4 卷积神经网络研究方向.....             | 19  |
| 2.4 免疫卷积神经网络结构设计.....             | 20  |
| 2.5 GPU 加速实现免疫卷积神经网络并行优化.....     | 23  |
| 2.6 本章小结.....                     | 24  |
| 第三章 免疫卷积神经网络性能研究.....             | 25  |
| 3.1 基于手写体识别的免疫卷积神经网络性能研究.....     | 25  |
| 3.1.1 MNIST 手写数字库简介.....          | 25  |
| 3.1.2 人工神经网络设计与实现.....            | 26  |
| 3.1.3 免疫卷积神经网络设计与实现.....          | 26  |
| 3.2 基于小图像识别免疫卷积神经网络性能研究.....      | 28  |
| 3.2.1 CIFAR-10 简介.....            | 28  |
| 3.2.2 CIFAR-10 免疫卷积神经网络设计与实现..... | 29  |
| 3.3 实验结果.....                     | 29  |
| 3.3.1 基于手写体识别的分类算法性能比较.....       | 29  |
| 3.3.2 基于小图像识别的分类算法性能比较.....       | 32  |





|                               |    |
|-------------------------------|----|
| 3.3.3 免疫卷积神经网络并行优化结果.....     | 33 |
| 3.4 本章小结.....                 | 34 |
| 第四章 免疫卷积神经网络在嵌入式图像识别应用研究..... | 35 |
| 4.1 嵌入式图像识别系统设计.....          | 36 |
| 4.1.1 核心算法的选择.....            | 37 |
| 4.1.2 训练集的构建.....             | 37 |
| 4.2 嵌入式硬件系统设计.....            | 38 |
| 4.2.1 S3C6410 处理器.....        | 38 |
| 4.2.2 摄像头采集模块.....            | 39 |
| 4.3 嵌入式软件系统设计.....            | 40 |
| 4.3.1 linux 系统移植.....         | 40 |
| 4.3.2 无线传输系统设计.....           | 40 |
| 4.3.3 图像采集程序设计.....           | 42 |
| 4.4 免疫卷积神经网络图像识别.....         | 43 |
| 4.4.1 ImageNet 简介.....        | 44 |
| 4.4.2 免疫卷积神经网络的构建.....        | 44 |
| 4.4.3 逐层可视免疫卷积神经网络.....       | 46 |
| 4.5 实验结果.....                 | 52 |
| 4.6 本章小结.....                 | 54 |
| 第五章 总结与展望.....                | 55 |
| 5.1 总结.....                   | 55 |
| 5.2 展望.....                   | 56 |
| 参考文献.....                     | 59 |
| 在校期间主要学术成果.....               | 63 |
| 致谢.....                       | 65 |

## 第一章 绪论

人工智能是一种智能行为，是众多科学家为了让机器模仿人类而开发的学科。这种行为能实现机器人模拟人脑视觉机理进行图像识别，自然语言识别和一些特定识别任务。广泛性是人工智能的特点之一，通过将机器学习，人工智能以及其他学科的结合，让我们在人工智能，机器学习的问题上拥有更多的方向和思路，从而促进人工智能快速发展。本章首先介绍本课题的背景和意义，还有国内外研究现状，最后介绍本文的创新点和主要工作。

### 1.1 课题研究背景和意义

机器学习（machine learning）是一个通过计算机不断模仿人类行为，并且不断获取这些新的数据和能力，通过自身学习和调节能力不断改善已有的这种知识结构的学科。对于机器是否能够像人类一样具有学习能力的问题，一直以来都得到业界的关注<sup>[1]</sup>。

机器学习经过这么多年的发展依然还有很多问题需要我们深入的去解决：比如图像识别问题，语音识别问题，自然语言理解问题。对于图像识别问题又衍生出来很多分支。字符识别、小图像识别、人脸识别等等都已经成为当今机器学习模式识别领域研究的热点。（以视觉感知为例子）：



图 1.1 机器视觉感知过程示意图

从上图我们可以看出，机器视觉感知过程和人脑视觉机理大同小异。首先，我们通过传感器（例如本文用的 CMOS 摄像头）来获得数据，其次，通过预处理、特征提取、特征选择，最后进行推理、预测或者识别<sup>[2]</sup>。对于最后机器学习的部分，我们现在的很大一部分研究工作是针对这个的，我们可以找到大量的文献和研究成果，本文也是立足于机器学习部分算法的改进，提出一种免疫卷积神经网络算法，这种算法能够更加准确的推理，预测或者识别我们的对象。中间的三部分（预处理，特征提取，特征选择），概括起来说就是特征表达。

卷积神经网络是一种多层感知器,它是专门针对二维特征图像设计的(现在已经扩展到三维特征图像),它和传统神经网络相比具有以下优点:容错性好、处理并行化、自学习能力。并且具有良好的鲁棒性,体现在其容错能力,由于卷积神经网络省略了传统神经网络中的人工特征提取过程,允许样本缺损情况出现。由于其强大的并行处理能力,能够多核多线程同时运行,因此,处理速度快,自适应性能好,具有较高的分辨率。它能够通过对网络结构进行重组,还有权值共享将特征提取的功能融合进多层感知器,将识别前复杂的图像特征提取过程省略。这一过程体现出卷积特性:局部感受野,权值共享,二次下采样,卷积神经网络的权重在训练过程中能够不断自我更新,更加体现其自我学习能力和自适应能力。

免疫系统是一个具有学习能力的系统,免疫系统的适应、学习和记忆能力不仅适用于优化,也适合开发用于机器学习的人工免疫系统。这一特点有点类似于卷积神经网络在机器学习方面的贡献。

我们说机器学习(machine learning)是一种能够通过自我学习获取数据调节自身的学科。我们通过对人脑视觉机理进行模拟,希望能够寻找到一种通用的免疫卷积神经网络用于模式识别。前面提到了机器学习在图像识别领域的发展,并且提到了几个重要的分支,本文将立足于手写体识别和小图像识别等实际问题,来提出一种有效的改进算法。

手写体识别应用前景。(1)在大规模数据统计中,例如行业年检,人口普查,手写体自动识别将减少人工输入的工作量。(2)在金融、财务、税务方面,大量的支票,税务单,财务报表不断增加,采用机器学习成为必然。(3)邮件分检,每年的双十一,我们的物流公司将会收到大批的订单,采用邮件自动分检将成为大势所趋<sup>[3]</sup>。

嵌入式图像识别技术作为人工智能在现实生活中的一项重大突破已经取得了很多重大成果,谷歌眼镜的成功研发象征着图像识别技术在可移动嵌入式设备的巨大飞跃。目前大多数的图像识别设备还是基于PC架构的,携带不方便,对于某些特定场合(如智能监控,户外非布控人员监控,户外拍照等)。人们需要一种携带方便,能够自动识别拍摄物的图像识别应用系统,例如,我们出去旅游爬山,往往会看到很多稀有的植物,我们自己都无法认知,那么我们多么希望能有一台相机是可以自动识别我们拍摄的物体的了,本文研究的嵌入式图像识别系统具有很好的应用前景。

## 1.2 国内外研究现状

### 1.2.1 卷积神经网络研究现状

上世纪 60 年代中期, Hubel<sup>[4]</sup>等人通过对猫视觉皮层系统的研究, 提出了感受野的概念。到了 80 年代后期, Fukushima<sup>[5]</sup>在感受野概念上提出了神经认知机概念, 这里才算是真正的实现了卷积神经网络。卷积神经网络真正的实现并且取得良好性能是在 1989 年, 加拿大多伦多大学教授 Yan LeCun 等人通过采用基于误差梯度的算法来训练卷积神经网络, 然后用于模式识别<sup>[6]</sup>。截止目前, 基于卷积神经网络模式识别系统已经成功的被评为模式识别领域中性能最好的系统之一。尤其是在手写字符识别领域, 还被公认是机器识别系统性能的评价标准<sup>[7]</sup>。

目前, 卷积神经网络方面的研究主要是集中在卷积神经网络的优化问题, CUDA 加速模型, 网络应用等方面:

卷积神经网络的优化问题,卷积神经网络的权重计算, 通常是通过 BP 算法训练多层神经网络, 人们可以得到从高维特征空间到易于分类的低维特征空间的复杂非线性映射。然而在微调模型损失函数的时候, 采用不同的方法精度和效率会有所不同, 为了求解整个网络的权重, 通常可以把一种或几种方法并行使用。

在卷积核函数的尺度问题上, 倘若我们把和特征图相关的全部权值集当成一个卷积核函数, 那么该函数就扮演着特征检测器的角色。然而, 想要用一个固定尺度的卷积核函数去提取不同尺度的特征并不现实, 所以我们需要用到不同尺度的卷积核。

在收敛速度的问题上, 由于不可能训练一次就能得到最优的学习模型, 为了使其具有适应性并且具有一定的抗噪能力, 网络可能需要进行多次训练。然而, 对于训练一个卷积神经网络所需的计算量是特别大的<sup>[8]</sup>, 因此, 是否能够快速收敛成了训练算法选择的关键。文献<sup>[9]</sup>提出来四种提高收敛速度的启发式算法, 可以总结为: 每一个自由参数都应该有自己的学习速率, 并且每一次学习速率都是能够随着时间变化而变化的, 总而言之, 学习速率应随着权值相关的误差梯度的变化行为来做出调整。

### 1.2.2 人工免疫系统研究现状

人工免疫系统是通过模拟生物免疫系统得来, 在目前人工免疫系统的定义还没有统一。

1958 年, 澳大利亚学者 burnet 提出了克隆选择学说, 并且凭借这一伟大成就获得 1960 年的诺贝尔奖。然后他完善了该原理, 克隆选择原理是免疫系统用来表明抗原受到刺激后的免疫应答基本特征的理论算法, 只有 Dasgupta 认为, 人工免疫系统由生物免疫系统启发而来的能够识别抗原的细胞才能进行克隆扩

增。

1974 年, 丹麦学者 jerne 提出了免疫系统理论, 并且奠定了免疫计算的基础, 鉴于他的杰出贡献, 最终在 1984 年获得诺贝尔奖<sup>[7]</sup>。

1986 年, Farmer 在 Jerne 的免疫理论基础, 提出了一个动态网络模型, 对免疫系统和机器学习进行开拓性的研究, 对未来学者研究新的免疫网络模型有重大启发。

1994 年, 美国学者 Forrest 提出一种否定选择算法, 用来生成一种可以耐受的检测器。让越来越多的学者开始关注免疫启发用于计算机安全。

1998 年, 国际会议 “IEEE Systems, Man and Cybernetics” 开展了对于人工免疫系统的专题讨论, “人工免疫系统及应用分会” 也是这个时候成立的。

2002 年, 召开第一届人工免疫系统会议, 这项会议是有英国的肯特大学举办。

目前人工免疫网络模型和免疫学习算法已经逐渐发展成为我们免疫系统的重要开发领域<sup>[10]</sup>。

### 1.2.3 嵌入式图像处理系统发展及现状

嵌入式系统用于专用设备, 设备的硬件资源有限, 并且成本要求严格, 对实时性要求高。国外, 消费电子智能化发展, 嵌入式占据重要地位。手机、电子字典、视频电话、DVD/VCD/MP3、Camera (DC)、数字摄像机、U 盘、机顶盒、高清电视、游戏机、智能玩具、路由器、汽车电子等等都是用的嵌入式系统。

在国内, 不同的机构针对具体的问题往往需要搭建具有实际应用价值的嵌入式图像处理系统, 这要求我们在图像识别算法选择和硬件设备设计方面综合考虑, 得到一种最优的嵌入式图像处理系统。

浙江大学设计了一种无人机, 可以通过视觉着陆。为了利用图像处理技术, 通过图像采集模块采集下方数据, 估计环境角度分析, 利用立体双目视觉系统进行数据采集, 能够获得较高准确度和速度。哈尔滨工业大学研究出了一种仿真机器人, 这个机器人性能高, 体积小, 功耗低, 结果简单。图像采集模块用的是 CMOS 摄像头, 用 DSP 芯片处理图像数据, 机器人可以自主导航。

国外, 美国的研究机构采用嵌入式技术和图像处理技术造出了火星车。这项技术采用的嵌入式系统是 VxWorks 操作系统, 加入图像处理识别算法, 能够自主认知火星所在地, 并且能够采集一些稀有图片, 并且传输回地球。

通过上面国内外嵌入式图像识别技术发展, 嵌入式设备图像识别算法仍然需要做很大改进, 主要是实时性和准确性。本文将着手软件算法部分, 通过改进卷积神经网络算法, 不论是在实时性, 还是准确性上都有一定的提高。



### 1.2.4 GPU 加速并行计算研究现状

GPU 是一款流处理设备，具有高浮点运算能力。针对它是否能适用于神经网络架构，提出了一种免疫卷积神经网络并行化识别算法，本系统采用计算统一设备架构（Compute Unified Device Architecture, CUDA<sup>[11]</sup>）技术。近几年，GPU 速度上的不断发展促进了图像处理技术、虚拟现实技术还有计算机仿真等相关研究技术领域的快速发展。给人们提供了一个良好的平台用于 GPU 图像处理之外的通用计算能力。GPU 通用计算实质上是采用 GPU 处理图像之外的广义并行计算。

CUDA(Compute Unified Device Architecture)是 NVIDIA 公司 2007 年提出的支持其 GPU 进行通用计算的编程模型和开发环境<sup>[12]</sup>。采用 CUDA 编程，能够让我们更加简单地在 GPU 设备上实现程序设计，不需要了解 GPU 上的图像处理单元，更加高效简单方便的使用 GPU 进行并程序序设计。

2014 年 9 月，NVIDIA 推出 cuDNN 库是一种的 GPU 加速库，用于深度神经网络，展现 NVIDIA 将带给机器学习的又一次性能上的飞跃。这款加速库强调性能、易用性和低内存消耗。NVIDIA 的 cuDNN 可以集成到不同级别的机器学习框架中，比如加州大学伯克利分校推出的一款流行的 Caffe 软件架构。简单的，插入式设计可以让开发人员专注于设计和实现神经网络模型，而不是调整性能，同时还可以在 GPU 上实现高性能现代并行计算。

采用 GPU 加速并行计算，我们可以总结出以下几个要点：

- (1)专为 NVIDIA 的 GPU 设计的，用于卷积神经网络前向和反向的微调程序。
- (2)专为最新的 NVIDIA 的 GPU 架构优化。
- (3)针对 4 维张量的任意维度排序，可以很容易集成到任何神经网络的执行中。
- (4)对于许多其他常见布局类（ReLU, Sigmoid, Tanh, pooling, softmax）前向和反向布局。
- (5)基于上下文的 API，可以很容易地多线程。

## 1.3 论文的创新

本文通过对国内外有关卷积神经网络，人工免疫系统，嵌入式图像处理系统和 GPU 加速并行计算的发展现状和研究成果进行整理和总结。并且对人工免疫神经网络和卷积神经网络的算法和结构进行详细阐述，通过人工免疫系统与卷积神经网络结合，提出了一种新的图像识别算法，免疫卷积神经网络算法，最后通过采用 NVIDIA 公司 GPU 加速并行计算，提高识别速度，满足当前嵌入式设备实时

性需求，并且搭建嵌入式图像实时识别系统。

## 1.4 本文的主要工作

本文通过对国内外有关卷积神经网络，人工免疫系统，嵌入式图像处理系统和 GPU 加速并行计算的发展现状和研究成果进行整理和总结。并且对卷积神经网络的算法和结构进行详细阐述，然后通过免疫算法和 NVIDIA 公司 GPU 加速并行计算来改进卷积神经网络，提出一种免疫卷积神经网络并行优化算法，并且与传统主要识别算法进行性能对比，突出其准确性高，实时性好等优点。最后用这种算法作为图像识别核心算子来搭建嵌入式图像实时识别系统。

(1)对卷积神经网络的网络结构以及参数进行分析，针对卷积神经网络网络结构复杂，训练耗时长，容易出现过拟合并且误分类高等缺点，本文基于人工免疫算法在实际中处理模式识别上面的优点用于改进卷积神经网络算法，提出了一种免疫卷积神经网络算法，该算法能够动态调节基函数平滑因子达到动态调节网络参数的能力。

(2)采用 NVIDIA 公司最新推出的 cuDNN 深度神经网络库，用来加速机器学习，使得我们的深度卷积神经网络模型可以用到对实时性要求很高的嵌入式平台。

(3)完成多功能图像识别系统 ARM+linux 平台的搭建，包括 linux 操作系统的裁剪、各硬件模块的驱动部分等。本系统是基于 linux 操作系统的，建设系统的第一步必须完成软硬件平台的构建，此阶段的工作内容主要在于 Linux 内核的裁剪、各个硬件模块驱动的编写、以及传感器信号的预处理、实现免疫卷积神经网络并行优化算法在嵌入式图像识别的应用研究。

本文一共分为五章，其中的第三章和第四章将描述本文具体工作。本文具体安排如下：

第一章绪论部分，主要介绍了本课题的研究背景和研究意义，国内外研究现状，最后介绍了论文的创新和主要研究工作。

第二章为五部分，首先介绍人工免疫系统在模式识别领域的基础理论与成功案例，为我们后面提出免疫卷积神经网络算法提供有利的方向。第二部分介绍了人工神经网络的基础理论，从最基础的单层神经元扩展到多层神经网络，并且对神经网络在训练中涉及到的算法和算法推导过程做了详细的介绍。第三部分对卷积神经网络相关结构和概念，尤其是卷积神经网络输出层 RBF 径向基网络模型进行详细介绍。第四部分是采用第一部分介绍的人工免疫算法改进第三部分介绍的卷积神经网络的输出层，然后通过第二部分介绍的前向，反向传导算法，对免

免疫卷积神经网络进行微调。第五部分是实现 NVIDIA 公司的 GPU 并行加速算法优化。

第三章是采用第二章介绍的改进后的免疫卷积神经网络分别在基于手写体识别库和小图像识别库的性能研究,主要是采用这些已有的数据库作为我们的识别算法的样本,通过实验对不同的分类算法性能进行分析比较,并且分别在 CPU 模式和 GPU 模式下查看样本训练所需的运行时间,最后在理论上分析采用免疫算法改进的卷积神经网络在处理输出层代价函数的性能上要优于经典卷积神经网络。

第四章主要是实现免疫卷积神经网络在处理嵌入式图像识别问题的应用研究,主要介绍了嵌入式图像采集与无线传输系统的搭建,然后根据第三章的结论,免疫卷积神经网络在小图像识别的准确率高,易于调节,并且具有很高的实时性等特点,所以本文采用免疫卷积神经网络优化算法作为嵌入式图像识别算子。并且采用逐层可视化的方法论述我们的免疫卷积神经网络模型的具体分类识别过程。最后采用免疫卷积神经网络模型搭建了一个 web 图像识别的 demo,用于处理识别嵌入式系统采集的图像,并最终将识别结果在嵌入式设备上显示。

第五章是对本文研究工作的总结和展望。





## 第二章 免疫卷积神经网络结构与算法

### 2.1 人工免疫网络概述

人工免疫系统我们通常称之为身体中必要的防御系统,用专业术语来讲我们可以称之为身体的模式识别系统,和大脑的模式识别系统是不一样的。免疫系统与大脑相比还是简单的多,免疫系统是可以用来辅助大脑进行识别的。免疫系统非常善于模式识别,我们不能通过常规的数字来估量其强大的识别效率,比如 Monte Carlo 方法<sup>[13]</sup>。

免疫系统通常是通过免疫应答反应来起作用,而应答反应的起始就是模式识别,顾名思义,免疫系统在免疫应答之前,需要先做一个判断,判断是自己还是非己。龚涛老师在其博士论文中提出了基于正常模型的免疫算法<sup>[14]</sup>,通过设计人工免疫系统的自体/异体检测算子来实现模式识别,并取得了良好的效果。如果是自身的物质,它就不会起反应;如果是外界物质,如外源性器官,细菌,病毒,它都会被识别出来,然后通过应答反应将其清除出去。截至目前,免疫系统识别自己和非己的重要标志是主要组织相容性抗原<sup>[15]</sup>。

#### 2.1.1 免疫系统模式识别

根据 Jerne 的免疫网络理论<sup>[16]</sup>。Farmer 等提出了一种被称为二进制位串的模型,并且还尝试把数学形式的理论免疫学与计算机智能相联系起来<sup>[17]</sup>。Timmis 提出了一种人工免疫网络学习算法,这种算法具有资源有限的特点<sup>[6]</sup>。输入的抗原通过提呈到神经元网络节点,接着,抗体 j 对所有抗原(或其它抗体) i 提呈产生的激励值  $s_j$  为

$$s_j = \sum_{i=1}^N (1 - D_{ij}) + \sum_{q=1}^M (1 - D_{jq}) - \sum_{q=1}^M D_{jq} \quad (2-1)$$

式中: N 为抗原数量; M 为相连的 B 细胞数量;  $D_{ij}$  是抗原 i 与 B 细胞 j 间的欧拉距离;  $D_{jq}$  是网络节点 q 与相连接的 B 细胞 j 间的欧拉距离。

$$D_{ij} = \left[ \sum_{r=1}^L (Vab_{jr} - Vag_{ir})^2 \right]^{\frac{1}{2}} \quad (2-2)$$

$Vab_{jr}$  是抗体 j 的值,  $Vag_{ir}$  是抗体 i 的值。

B 细胞与外部抗原之间的亲和力  $Aff_{ij}=1-D_{ij}$  与距离成反比。(式 2-1) 的激励值决定了我们是否需要调整网络的节点参数。

Payne 等应用 aiNet 网络提出来了一种数据聚类算法。这种算法在确定 RBF 神经网络中径向基函数的中心参数方面取得了成功。但是由于径向基函数的平滑因子是固定的,通常模式识别的误差比较难以降低<sup>[18]</sup>。

人工免疫网络的提出被学术界归为是一种智能算法,具有分布式,自组织,鲁棒性,记忆与学习等特点<sup>[19,20]</sup>。对于传统的免疫系统和神经网络,网架结构的组成都是通过种群之间的相互连接完成的<sup>[21]</sup>。采用人工免疫算法来改进卷积神经网络输出层,可以有效地确定输出层径向基函数的中心位置<sup>[22]</sup>。还可以进一步动态调整网络的结构参数,得到一组最优的加权系数。基于此,文中提出一种免疫卷积神经网络算法。

### 2.1.2 免疫分类算法研究

基于免疫系统开发的模式识别分类技术研究方面, Farmer 和 Perelson 最早证实了分类器和独特型免疫网络模型之间是具有相似性的<sup>[23,24]</sup>。这个发现促使认知科学像人工免疫学方向的发展。

Cooke 和 Hunt 最早将独特型免疫网络思想应用到机器学习问题<sup>[25~27]</sup>。分类算法,本文提出的免疫卷积神经网络算法,从机器学习的角度来说,也是属于监督型学习算法。

Carter 在 2000 年提出了一个监督学习模型<sup>[28]</sup>。这个监督学习算法基于免疫系统机制,实现模式识别和分类。免疫算法进化模糊规则的提出是采用一种免疫启发的模式分类集成系统,这种系统用于克隆选择和免疫网络<sup>[29]</sup>。采用免疫算法来找到问题的多个良好解,就可以很方便的在一次运算后建立准确的,多样化的模糊识别系统。通过将免疫算法改进的 K 最近邻混合分类系统算法在癌症诊断上面取得了 99.14% 的准确率<sup>[30]</sup>。自主导航的免疫分类器网络能够根据环境变化调解网络属性,在机器人自主导航中验证了算法的有效性<sup>[31]</sup>。文献提出加权人工免疫系统,主要基于形态空间欧几里得距离加权计算来进行分类,算法在实际心脏病等疾病上实验,与传统算法有可比性<sup>[32]</sup>。文献作者将 AiNet 产生的记忆细胞作为分类器,与 K 最近邻结合,得到了基于人工免疫网络分类器,与传统算法比较性能更好<sup>[33]</sup>。

Wakins 提出了基于资源有限人工免疫系统的免疫分类器 AIRS<sup>[34,35]</sup>。这种方法的提出是受到 Timmis 早起提出的 RLAIIS 方法的启发,尤其是 RLAIIS 中 ARBs 概念的影响。该方法是对 RLAIIS 方法的改进,是目前人工免疫学中较为成功的

一种分类器。

## 2.2 人工神经网络

### 2.2.1 神经网络模型

我们前面已经介绍了分类算法当前基本上都是一种监督学习算法, 这里我们通过监督算法来分析神经网络模型。假设我们将  $(x(i), y(i))$  作为神经网络输入训练样本集,  $h_{w,b}(x)$  是通过神经网络算法提出的一种假设模型, 具有复杂且非线性的特点。它可以通过参数  $W, b$  来拟合我们的数据。

首先, 我们对单个神经元被激活的网络模型进行分析。这个“神经元”是一个运算单元, 它是以  $x_1, x_2, x_3$  及截距+1 为输入, 输出是

$$h_{w,b}(x) = f(w^T x) = f(\sum_{i=1}^3 w_i x_i + b)。$$

下面是在神经网络中常用的非线性激活函数。

(1) S 型函数 (Sigmoid Function)

$$f(x) = \frac{1}{1 + e^{-ax}} (0 < f(x) < 1) \quad (2-3)$$

(2) 双曲正切函数 (tanh)

$$f(x) = \frac{2}{1 + e^{-ax}} - 1 (-1 < f(x) < 1) \quad (2-4)$$

### 2.2.2 反向传导算法

对于一个带标签的样本集  $\{(x^{(1)}, y^{(1)}), \dots, (x^{(m)}, y^{(m)})\}$ , 这个样本集有  $m$  个样本, 我们可以用批量梯度下降法来求解<sup>[7]</sup>。单个样例  $(x, y)$ , 其代价函数为:

$$J(W, b; x, y) = \frac{1}{2} \|h_{w,b}(x) - y\|^2 \quad (2-5)$$

公式 (2-5) 是一个方差代价函数, 前面二分之一是为了使我们的计算更加方便。下面, 假设有一个包含  $m$  个样例的数据集, 整体代价函数可以通过下式计算:

$$\begin{aligned}
 J(W, b) &= \left[ \frac{1}{m} \sum_{i=1}^m J(W, b; x^{(i)}, y^{(i)}) \right] + \frac{\lambda}{2} \sum_{l=1}^{n_l} \sum_{i=1}^{s_l} \sum_{j=1}^{s_l+1} (W_{ji}^{(l)})^2 \\
 &= \left[ \frac{1}{m} \sum_{i=1}^m \left( \frac{1}{2} \| h_{W,b}(x^{(i)}) - y^{(i)} \|^2 \right) \right] + \frac{\lambda}{2} \sum_{l=1}^{n_l} \sum_{i=1}^{s_l} \sum_{j=1}^{s_l+1} (W_{ji}^{(l)})^2
 \end{aligned} \tag{2-6}$$

公式 (2-6) 中第一项  $J(W, b)$  是均方差项，第二项是为了减小权重幅度从而防止过度拟合问题的一个权重衰减项<sup>[36]</sup>。权重衰减参数  $\lambda$  是用来控制这两项的重要性的。 $J(W, b; x, y)$  是对一个样本的方差代价函数； $J(W, b)$  是整体样本的代价函数，后面还包含权重衰减项。

上面的代价函数常被用于处理分类和回归方面的问题。对于分类问题，如果使用 sigmoid 激活函数，那么其标签为 0 和 1。如果使用 tanh 激活函数，那么应该其标签为 -1 和 1。

为了获得准确的分类结果，需要调节参数  $W$  和  $b$  来求函数  $J(W, b)$  的最小值。首先需要将  $W_{ij}^{(l)}$  和  $b_i^{(l)}$  初始化为一个无限接近 0 的随机值。目标函数需要通过批量梯度下降法来优化。由于  $J(W, b)$  是一个非凸的函数，梯度下降法很可能会出现局部最优解收敛；在实际应用中，梯度下降法能够取得很高的准确率。需要注意的是，我们要对参数不是全部置为 0，而是进行随机的初始化<sup>[37]</sup>。在梯度下降法中，每一次的迭代都应该按照公式 (2-7) 和 (2-8) 来对参数  $W$  和  $b$  进行微调：

$$W_{ij}^{(l)} = W_{ij}^{(l)} - \alpha \frac{\partial}{\partial W_{ij}^{(l)}} J(W, b) \tag{2-7}$$

$$b_i^{(l)} = b_i^{(l)} - \alpha \frac{\partial}{\partial b_i^{(l)}} J(W, b) \tag{2-8}$$

其中  $\alpha$  是学习速率。其中关键步骤是计算偏导数。对于偏导数计算的问题，通常采用反向传播算法，能够取得很好的效果。 $\frac{\partial}{\partial W_{ij}^{(l)}} J(W, b; x, y)$  和

$\frac{\partial}{\partial b_i^{(l)}} J(W, b; x, y)$  是一个样本所对应的代价函数的偏导数。整体样本代价函数

$J(W, b)$  的偏导数为：

$$\frac{\partial}{\partial W_{ij}^{(l)}} J(W, b) = \left[ \frac{1}{m} \sum_{i=1}^m \frac{\partial}{\partial W_{ij}^{(l)}} J(W, b; x^{(i)}, y^{(i)}) \right] + \lambda W_{ij}^{(l)} \tag{2-9}$$

$$\frac{\partial}{\partial b_i^{(l)}} J(W, b) = \frac{1}{m} \sum_{i=1}^m \frac{\partial}{\partial b_i^{(l)}} J(W, b; x^{(i)}, y^{(i)}) \quad (2-10)$$

公式(2-9)和公式(2-10)中，我们可以看出多出来一个权重衰减，这是由于权重衰减是作用于  $W$  而不是  $b$ 。

反向传播算法的设计如下：给定一个单一样本  $(x, y)$ ，首先进行“前向传导”运算，把网络中所有的激活值和输出值都计算出来。然后，计层的每一个节点  $i$ ，我们计算出第  $l$  层的每一个节点  $i$  的“残差”  $\delta_i^{(l)}$ 。该残差可以看成是一种影响最终输出的影响因子。

对于输出节点，计算网络激活值和实际值的差  $\delta_i^{(n_l)}$  (层表示输出层)。通过节点残差的加权平均值来计算  $\delta_i^{(l)}$ ， $a_i^{(l)}$  是这些节点的输入。

采用前面描述的前向传导算法公式来推导出  $L_2, L_3, \dots, L_{n_l}$  得到输出层的激活值。

对于输出层第  $n_l$  层的每个输出单元  $i$ ，我们公式(2-11)来计算残差：

$$\delta_i^{(n_l)} = \frac{\partial}{\partial z_i^{(n_l)}} \frac{1}{2} \|y - h_{W,b}(x)\|^2 = -(y_i - a_i^{(n_l)}) \bullet f'(z_i^{(n_l)}) \quad (2-11)$$

对  $l = n_l - 1, n_l - 2, n_l - 3, \dots, 2$  的各层，我们采用(2-12)的公式来计算第  $l$  层的第  $i$  个节点的残差：

$$\delta_i^l = \left( \sum_{j=1}^{s_{l+1}} W_{ji}^{(l)} \delta_j^{(l+1)} \right) f'(z_i^{(l)}) \quad (2-12)$$

偏导数计算公式如下：

$$\frac{\partial}{\partial W_{ij}^{(l)}} J(W, b; x, y) = \alpha_j^{(l)} \delta_i^{(l+1)} \quad (2-13)$$

$$\frac{\partial}{\partial b_i^{(l)}} J(W, b; x, y) = \delta_i^{(l+1)} \quad (2-14)$$

通过上面对于反向传导算法的描述，我们可以将反向传播算法总结如下：

第一步，采用前向传导算法推导出各层的激活值和节点输出值。

第二步，对神经网络的最后一层输出层，采用公式(2-15)计算出输出层和样本标签的残差：

$$\delta^{(n_l)} = -(y - a^{(n_l)}) \bullet f'(z^{(l)}) \quad (2-15)$$

第三步，对于隐含层  $l = n_l - 1, n_l - 2, n_l - 3, \dots, 2$  的各层，采用公式 (2-16) 计算各个节点的残差：

$$\delta^l = ((W^{(l)})^T \delta^{(l+1)}) \bullet f'(z^l) \quad (2-16)$$

第四步，最终偏导数采用下面的公式计算：

$$\nabla_{W^{(l)}} J(W, b; x, y) = \delta^{(l+1)} (a^{(l)})^T \quad (2-17)$$

$$\nabla_{b^{(l)}} j(W, b; x, y) = \delta^{(l+1)} \quad (2-18)$$

## 2.3 卷积神经网络

卷积神经网络作为人工神经网络衍生的一种用于深度学习的网络架构。已经成功应用于手写体识别<sup>[7,38]</sup>，语音识别<sup>[39]</sup>，人眼检测<sup>[40]</sup>，人脸识别<sup>[41]</sup>，行人检测<sup>[42]</sup>，机器人导航<sup>[43]</sup>。卷积神经网络有点类似于生物神经网络，具有权值共享的特点，这一特点不仅使得网络模型的复杂度降低，权值的数量也减少了。所以卷积神经网络多被用于处理多维输入图像问题，避免了传统识别算法中复杂的特征提取和数据重建的过程。卷积网络是一个多层感知器，这种网络结构能够对平移和比例缩放等变形具有高度不变性。

### 2.3.1 卷积神经网络的架构

卷积神经网络是一个多层监督学习神经网络，隐含层中的卷积层和下采样层是实现卷积神经网络特征提取的核心模块。该网络模型通过采用梯度下降法最小化损失函数对网络中的权重参数逐层反向调节，通过频繁的迭代训练提高网络的精度<sup>[32]</sup>。图 2.1 是卷积神经网络结构图。

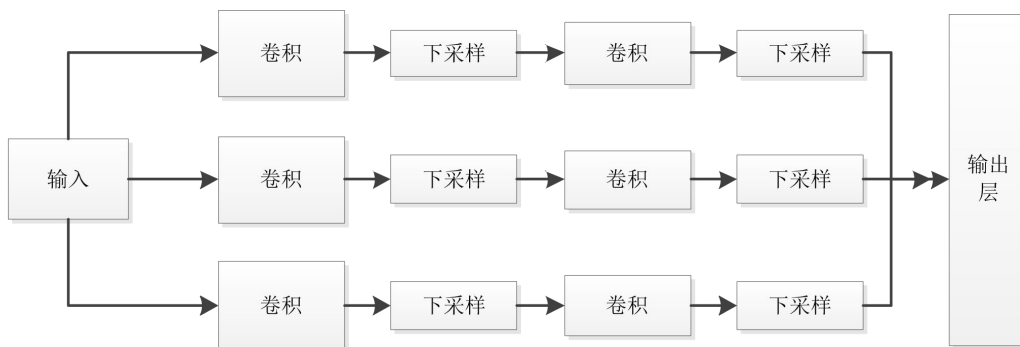


图 2.1 卷积神经网络的结构图



输入图像与三个卷积滤波器进行卷积，卷积滤波器经过训练和加偏置。滤波过程如图 2.1，在卷积处理后，会产生三个特征图。接着就是下采样过程，就是将特征图中的特征进行求和，加权值，加偏置，然后通过一个 Sigmoid 函数得到 S2 层的特征图。这些特征图再经过卷积滤波得到 C3 层。再次下采样，产生 S4 层。最终，这些特征向量通过全连接网络输出层输入到传统的神经网络，得到输出。

C 层（卷积层）是特征提取层。神经元的输入与前一层的局部感受野相连，并提取该局部的特征，通过提取该局部特征来确定它与其他特征间的位置关系；S 层（下采样层）是特征映射层，每一个特征映射都可以看做一个平面，平面上所有神经元的权值是相等的。采用 sigmoid 函数作为激活函数，体现卷积神经网络特征提取的位移不变性。

神经元权值共享的特点减少了网络参数的个数，降低了选择网络参数的复杂度。

卷积神经网络中习惯将特征提取层（C-层）和求局部平均与二次提取的下采样层（S-层）假体使用，这种特征提取结构使网络在进行识别时对输入的样本有较高的畸变容忍能力。

卷积神经网络的隐含层是由卷积层和最大池采样层交替组成，高层是全连接层对应的是传统的多层感知器的隐含层和逻辑回归分类器。第一个全连接层的输入是由卷积层和下采样交替提取的特征图像。

卷积神经网络最后一个特征提取阶段提取的特征通常作为最后一层输出层的输入。输出层是一个权值可微的分类器，可以让整个网络使用基于梯度的学习方法来进行全局训练。

常用的权值可微的分类器包括：径向基网络(Radial Basis Function Networks)、多项式逻辑回归(Multinomial Logistic Regression)、一层或两层的全连接神经网络。

也可以使用权值不可微的分类器：支持向量机，特征提取混合模型。

### 2.3.2 径向基网络

RBF 网络相比于传统神经网络能够更好的逼近任意非线性函数，并且在理解系统规律性方面具有良好的效果。具有良好的泛化能力，收敛速度快，在非线性和模式识别、时间序列分析、数据分类、图像处理、系统建模、控制和故障诊断等方面取得重大成果。

由于 RBF 网络中的可调参数（权值或阈值）能够对任何一个输出都有影响，我们也将 RBF 网络称为全局逼近网络。



RBF 网络也有其缺点,对于每次输入,网络上每个权值都需要调整,这就带来了全局逼近学习速率会变慢的缺点。BP 网络就是一个典型的例子。

如果对于输出产生影响的只是输入空间的某个局部区域,那么该网络称为局部逼近网络。常见的局部逼近网络有小脑模型(CMAC)网络、RBF 网络和 B 样条网络等。

径向基函数(Radical Basis Function, RBF)方法是 Powell 在 1985 年提出的。径向基函数是某种沿径向对称的标量函数。它是空间任意一点到中心的欧氏距离的单调函数,记作  $k(\|x-c\|)$ ,它的作用是局部的(即当  $x$  远离  $c$  时函数取值很小)。例如高斯径向基函数:

$$h(x) = \exp\left(-\frac{(x-c)^2}{r^2}\right) \quad (2-19)$$

在 1988 年,Moody 和 Darken 提出了一种能够以任意精度逼近任意连续函数属于前向神经网络类型的网络结构,即 RBF 神经网络。很适合用于解决分类问题。

$$y_j = \sum_{i=1}^h w_{ij} \exp\left(-\frac{1}{2\sigma^2} \|x_p - c_i\|^2\right) \quad j=1,2,\dots,n \quad (2-20)$$

RBF 网络是一种和多层前向网络类似的三层前向网络。

第一层是输入层,它是由信号源结点组成的;

第二层是隐含层,隐单元数是根据描述的对象定的,采用 RBF 径向基函数作为隐单元的变换函数,它是中心点径向对称且衰减的,是一种非负非线性函数。

第三层是输出层,能够对输入模式的作用作出响应。

从输入空间到隐含层空间的变换是一种非线性变换,而从隐含层空间到输出层空间变换是一种线性变换。

RBF 网络的基本思想是:选择 RBF 函数作隐单元的“基”来构成隐含层空间。这样就可将输入矢量直接映射到隐空间。

根据 Cover 定理,原来低维空间不可分的数据映射到了高维空间会变得可分。RBF 网络的隐层的功能就是将低维空间到高维空间的非线性映射的过程。接着在这个高维空间进行曲线拟合。等同于在一个隐含的高维空间寻找能最佳拟合训练数据的平面。这是和多层感知机 MLP 不同的地方。

确定了 RBF 函数的中心点以后,这种映射关系也就确定了。隐含层空间通过线性映射到输出空间,通过隐单元输出的线性加权和(网络可调参数)来得到输出。总的来看,网络的输入到输出的映射是一种非线性映射,而网络输出对可调参数而言却又是一种线性映射。这样网络的权值就可以由线性方程组来直接求解,不仅加快了学习速率,并且有效的避免了局部极小问题。

多层感知器的隐节点基函数采用线性函数，而 RBF 网络的隐节点的基函数采用距离函数（如欧氏距离）。多层感知器的激活函数采用 Sigmoid 函数或 Tanh 函数，而 RBF 网络的激活函数采用径向基函数（如 Gaussian 函数）。

RBF 的设计主要包括结构设计和参数设计两个方面：结构设计就是说隐藏层含有几个节点比较合适，参数设计就是对网络各参数进行求解。通过输入到输出的网络映射函数公式可以看出，RBF 网络的参数主要包括：隐含层到输出层的权值、径向基函数的中心和方差。本文提出的免疫卷积神经网络算法通过免疫算法改进卷积神经网络最后一层输出层，输出层采用的正是这里介绍的 RBF 网络，我们通过免疫算法改进来确定这三种参数。这边先介绍一下通用的两种方法。

第一种方法是通过非监督方法和监督方法（最小二乘法）相结合来得到径向基函数的中心和方差，还有隐含层到输出层的权值。具体如下：

（1）首先，从样本中随机选择  $h$  个样本作为  $h$  个径向基函数的中心。最好选择采用聚类的方法，比如可以采用 K-means 聚类来得到  $h$  个聚类中心来作为径向基函数的  $h$  个中心。

（2）RBF 神经网络的方差可以采用（2-21）公式来求取（基函数采用高斯函数）：

$$\delta_i = \frac{c_{\max}}{\sqrt{2h}}, i=1,2,\dots,h \quad (2-21)$$

式中  $c_{\max}$  为所第一步中选取中心点间的最大距离， $h$  是采用的隐层节点的个数。扩展常数这么计算可以避免径向基函数出现太尖或太平的情况。

最后采用最小均方误差 LMS 来确定隐含层至输出层之间神经元的连接权值公式如下：

$$W = \phi^+ d \quad (2-22)$$

$$\phi^+ = (\phi^T \phi)^{-1} \phi \quad (2-23)$$

第二种方法采用监督学习算法来对网络中所有的参数进行训练。主要体现在对代价函数（均方误差）进行梯度下降，然后进行参数修正上面。具体如下：

（1）对径向基函数的中心，方差还有权值进行初始化。也可以采用方法一中的（1）来初始化径向基函数的中心。

(2) 采用梯度下降的方法，来对网络中的三种参数都进行监督训练，达到参数优化的目的。代价函数是网络实际输出和期望输出之间的均方误差：

$$E = \frac{1}{2}(y(x) - d)^2 \quad (2-24)$$

网络不断训练优化参数，这是一个长期的迭代过程，迭代过程中不断地在误差梯度的负方向以一定的学习率来调整参数。

$$\Delta c_j = -\eta \frac{\partial E}{\partial c_j} = \eta \frac{w_j}{\delta_j^2} \sum_{i=1}^P e_i G(\|X_i - c_j\|)(X_i - c_j) \quad (2-25)$$

$$\Delta \delta_j = -\eta \frac{\partial E}{\partial \delta_j} = \eta \frac{w_j}{\delta_j^3} \sum_{i=1}^P e_i G(\|X_i - c_j\|) \|X_i - c_j\|^2 \quad (2-26)$$

$$\Delta w_j = -\eta \frac{\partial E}{\partial w_j} = \eta \sum_{i=1}^P e_i G(\|X_i - c_j\|) \quad (2-27)$$

### 2.3.3 卷积网络的训练过程

模式识别领域，我们运用神经网络算法大多数采用的还是有指导学习，属于的是监督性学习算法，然而无指导学习更多是用于聚类分析。有指导学习下的模式识别就是我们已经知道了样本的类别，它的样本空间分布不再是自然分布，而是一种有规律分布，我们需要找到同类和不同类之间的特征向量，以达到模式识别的目的。也可以寻找一个分类的边界，让不同类的样本可以划分到不同的区域内<sup>[44]</sup>。这是一个复杂的学习过程，需要耗费很长时间。本文所使用的网络也是一种有指导学习网络，通过前面提出的免疫模式识别算法对这个有指导学习网络的输出层进行改进，使得网络参数的调整更加方便，分类结果准确度更高。卷积神经网络就是这样一种有指导的学习网络，卷积网络它在本质上是一种输入到输出的映射，可以对大量的输入和输出之间的映射关系进行学习分析，而不需要任何精确的数学表达式，只要采用训练好的模型作用在训练样本，网络就具有了这种映射能力。卷积网络的样本集是由：（输入向量，理想输出向量）的向量对构成的。这些向量可以从实际运行系统中采集。在训练开始之前，应该对所有的权值参数小随机化。“小随机数”是用来保证训练网络不会因权值过大出现过拟合的状况。选择不同的权值参数是为了让网络训练正常调整。

卷积神经网络训练算法类似于传统的 BP 算法，主要包括下面 4 步，我们通常把这 4 步分为两个阶段：

第一个阶段是前向传播阶段，过程如下所示：

A. 首先，从样本集里面选取一个样本(X,Y<sub>p</sub>)，然后把 X 作为网络输入；

B. 通过前面提出的前向算法计算出相应的实际输出 O<sub>p</sub>。

在这个过程中，我们的样本信息从输入层经过逐级的变换，传递到输出层。在这个过程中，网络实际输出由 (2-28) 公式计算：

$$O_p = F_n(\dots(F_2(F_1(X_p W^{(1)}) W^{(2)}) \dots) W^{(n)}) \quad (2-28)$$

第二个阶段是向后微调阶段，过程如下所示：

A. 将第一个阶段中计算得到的实际输出  $o_p$  与相应已知的理想输出  $y_p$  的求最小方差；

B. 采用极小化误差的方法来调整权矩阵。我们要考虑获得高精度的前提下微调整个网络。极小误差的值  $E_p$  用式 (2-29) 计算。作为网络关于第 p 个样本的误差测度。对于整个样本集的误差测度是：  $E = \sum E_p$ 。

$$E_p = \frac{1}{2} \sum_{j=1}^m (y_{pj} - o_{pj})^2 \quad (2-29)$$

中间层各单元的输出为式 (2-30)：

$$h_j = f\left(\sum_{i=0}^{N-1} V_{ij} x_i + \phi_j\right) \quad (2-30)$$

而输出层各单元的输出是式 (2-31)：

$$y_k = f\left(\sum_{j=0}^{L-1} W_{kj} h_j + \theta_k\right) \quad (2-31)$$

f(\*)是采用的是 S 型的激励函数 (2-32)：

$$f(x) = \frac{1}{1 + e^{-kx}} \quad (2-32)$$

#### 2.3.4 卷积神经网络研究方向

目前，卷积神经网络在图像识别问题上还存在很多需要改进和突破的地方，本文根据当前卷积神经网络研究需要改进的三个方面进行描述，为我们后面改进卷积神经网络算法的提出做了一个好的铺垫：

(1)网络结构方面：卷积神经网络做为一种多层神经网络，网络结构复杂，训练耗时较长。当前的研究热点集中在，处理相同的一个数据集和不同数据集上都能够获得良好的分类性能的网络结构。比如找到一种对卷积神经网络的网络结构动态调节的方法<sup>[45]</sup>：我们从单个简单卷积核进行训练，逐渐增加卷积神经元并修改和新增连接权重，训练结果达到预期目标的时候，训练结束。

(2)系统硬件实现方面：总所周知，卷积神经网络相比较传统神经网络的有点就是它具有很强的并行处理的特点，所以对于我们想要通过硬件加速网络效率是可行的。我们可以采用专门用于卷积神经网络的大规模集成电路。利用 CUDA 和 GPGPU 的并行处理能力来达到提升卷积神经网络训练算法速度<sup>[46]</sup>。

(3)网络应用研究：卷积神经网络已经成功的应用在图像识别，语音识别，物体检测等模式识别的各个领域，尤其是在静态图像识别方面，卷积神经网络表现出了较好的性能<sup>[47,48]</sup>，并且延伸到视频数据的识别问题上<sup>[49]</sup>。

## 2.4 免疫卷积神经网络结构设计

免疫改进卷积神经网络的算法是通过免疫分类算法改进卷积神经网络的输出层，通过不断调节动态因子，免疫卷积神经网络算法是在经典卷积神经网络 LeNet-5 基础上做出的改进，我们在以下方面做出改进：

(1) LeNet-5 卷积神经网络采用的是双曲线正切 ( $\tanh$ ) 作为所以节点的激励函数。在 ICNN-1 中我们采用 Relu (Rectified linear units) 来代替传统的  $\tanh$  引入非线性。由于早期使用 sigmoid 或  $\tanh$  作为激活函数，深度神经网络在做无监督学习的时因为梯度消失的问题会无法收敛，Relu 就没这个问题。Relu 的线性修正公式为，它是 purelin 的折线版。它的作用当计算结果小于 0，就让它等于零，否则保持值不变，这是一种强制置零的方法，说明 Relu 有适度引导稀疏的能力。

(2) 在 LeNet-5 卷积神经网络模型 F6 层采用的是径向基函数的连接方式，免疫卷积神经网络模型，通过人工免疫算法改进 RBF 神经网络。




图 2.2 免疫改进 RBF 分类模型

图 2.2 中，免疫网络的输入模式抗原为  $\{x_i \mid i = 1, 2, \dots, n\}$ ， $x_i$  由卷积神经网络产生，即输入为前面隐含层的输出，中间层为一层，网络节点  $\{g_i \mid i = 1, 2, \dots, m\}$ ，每个节点对应一个输入变量函数，输出（模式识别）  $\{y_k \mid k = 1, 2, \dots, p\}$  为网络节点函数线性叠加。

$$y_k = \sum_{j=1}^m [w_{kj} g_j(x_1, \dots, x_n)], k = 1, 2, \dots, p, \quad (2-33)$$

网络节点（抗体）之间亲和力体现了节点的连接强度，会表现出激励和抑制效应。免疫网络将卷积网络采集到的特征作为抗体，通过抗体的出入通道来进行网络的动态调节，移除未受激活或死亡的抗体（节点），增加新生的抗体（抗体），网络节点函数  $g_j(\bullet)$  取径向基高斯函数，

$$g_j(x) = \exp\left[-\frac{\|x - u_j\|^2}{2\delta^2}\right], j = 1, 2, \dots, m \quad (2-34)$$



式 (2-34) 中  $u_j$  是第  $j$  个节点的中心向量;  $\delta_j$  为基函数的平滑因子。

我们采用 RBF 网络来确定奇函数的个数时, 输入向量应该线性无关, 基函数的个数和中心不能够确定<sup>[50]</sup>。采用人工免疫网络算法能够有效的对数据进行网络聚类 and 模式识别。

采用人工免疫学习算法改进 RBF 神经网络, 并且作用于输入向量, 对免疫改进后的卷积神经网络进行有监督学习, 步骤如下:

搭建免疫卷积神经网络架构, 在网络输出层采用聚类方法确定基函数的个数和基函数的中心, 然后调整节点和平滑因子  $\delta_j$ 。

训练整个网络, 得到基函数的系数  $W$ , 使得免疫卷积神经网络网络的实际输出  $y$  逼近目标输出  $z$ , 平均误差如下

$$e_{av} = \sum_{a=1}^{N'} |y^{(a)} - z^{(a)}| / N' \quad (2-35)$$

输入模式与识别模式 (加权  $w_{kj}$ , 输出  $y_k$  和基函数系数  $u_j$  与  $\delta_j$ ) 采用的是实数编码。评价指标是抗体的激励与有效输出的平均误差 (或适应度  $Fit = \exp(-e_{av})$ ),  $\delta_j$  的修正量  $\delta_j'$  与  $Fit$  还有  $w_{kj}$  (优选抗体值) 有关,

$$\delta_j' = \delta_j + (w_{kj} - v_0) / (1 + Fit), j = 1, 2, \dots, m \quad (2-36)$$

$v_0$  约为函数幅值的一半。改进的输出层免疫分类算法流程图如图 2.3 所示,

首先, 在确定网络结构和节点函数情况下, 通过不断地调节平滑因子  $\delta_j$ , 直到满足阶段优化终止条件。其次, 改进免疫网络结构, 逐步精确节点参数, 并且我们可以将数据聚类的操作放在第二阶段, 有效减少算法运行时间。

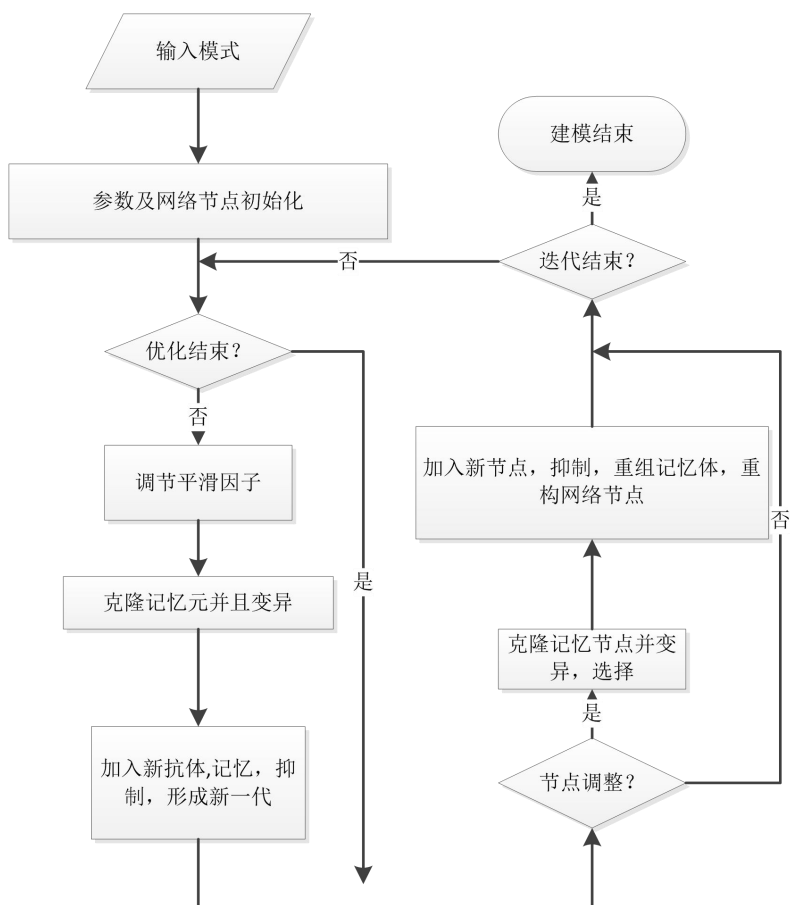


图 2.3 免疫优化分类算法流程图

## 2.5 GPU 加速实现免疫卷积神经网络并行优化

DNNs 和 CNN 需要大量的计算，特别是在训练阶段。神经网络通过提供输入到网络，并让所得到的神经元的激活向上流动通过网络向输出层，其中，所述结果进行比较正确的答案的训练。计算用于在输出层的每个单元中的错误，此错误是“反向传播”向下通过网络由一个小的量来调节每个连接权重。因此存在的输入以产生输出的“前向”和“后向”，以通过网络时训练传播错误。当展开时，仅仅使用前向传导。

最先进的 DNNs 和 CNN 可以通过反向传播来调整数以百万计及超过十亿的参数。此外，DNNs 需要大量的训练数据，以达到较高的精度，这意味着数十万到数百万的输入样本将不得不通过前向传导和反向传导微调。由于神经网络是由大量相同的神经元产生，他们本质上是高度并行的。这种并行自然地映射到图形



处理器，相对于 CPU 提供了一个显著的加速效果。

NVIDIA 的 cuDNN 是专门为 DNNs 设计的 GPU 加速库，用于机器学习，提供了我们所需要的深度神经网络中的调整策略。包括 convolution, pooling, softmax, 激活函数包括 Sigmoid, Rectified linear (ReLU), Hyperbolic tangent (TANH)

cuDNN 功能可定制的数据布局，支持灵活的维度排序，跨步和分区域对作为输入和输出的所有的程序四维张量。这种灵活性可以方便地集成到任何神经网络的实现，避免有时必须与 GEMM 型卷积输入/输出换位步骤。

cuDNN 是线程安全的，并提供了基于上下文的 API，它可以很容易地和多线程（可选）以及 CUDA 流进行交互。这允许开发人员使用多个主机线程和多个 GPU 时显式地设置控制库，并且确保我们特定的线程能够一直运行在特定的 GPU 核上面。

该 cuDNN 库是针对 DNN 框架（如 Caffe, Torch）的开发商设计的。很容易直接使用，你不需要为了使用它去学习 CUDA。下面的将简单介绍如何分配存储输入一批图像和 cuDNN 卷积滤波器，以及如何通过卷积层运行批处理的前向传导过程。

我们调 `cudaSetTensor4dDescriptor()` 和 `cudaSetFilterDescriptor()` 去定义输入到本卷积层和过滤器的参数。

调用 `cudaSetConvolutionDescriptor` 去初始化卷积，例如填充和跨步参数这一层。

调用 `cudaGetOutputTensor4dDim()`，计算卷积的输出维度。下一个调用简单的配置这一层的输出分配存储，然后通过 `cudaConvolutionForward()` 执行 NVIDIA 调谐卷积。

## 2.6 本章小结

本章整理和总结了人工免疫算法在模式识别分类算法中的成功应用以及在处理实际机器学习问题中的突出贡献。并对人工神经网络特别是卷积神经网络的算法进行了介绍和总结，针对卷积神经网络研究存在的问题，通过将人工免疫系统与卷积神经网络相结合，并且对经典卷积神经网络最后一层输出层的改进，这一发现能够为当下处理特定的模式识别，需要设计不同的卷积神经网络架构的缺点，本文介绍的改进卷积神经网络具有网络节点，参数自调节的能力，有效的提高了卷积神经网络的收敛性和准确性。论证了采用人工免疫算法优化卷积神经网络的论点具有可行性和可操作性

## 第三章 免疫卷积神经网络性能研究

本章分别基于手写体识别和小图像识别两个典型的图像识别库做性能研究，手写体识别和小图像识别问题国内外已经提出了各种各样的算法研究，并且取得了很高的准确度。当前，LeCun提出的卷积神经网络一直占据领先地位，能够获得很高的准确率，并且收敛性能和训练速度上比其他训练算法更好，本文是在已有卷积神经网络算法的基础上将人工免疫系统与卷积神经网络相结合，通过对输出层RBF函数单元的改进，动态调谐网络参数以及基函数的平滑因子，有效的提高了卷积神经网络的收敛性和准确性。该算法具有数据聚类，参数优化，模式识别等优点。本文提出的免疫卷积神经网络算法在手写体识别和小图像识别上相对于经典卷积神经网络分类算法和其它分类算法具有更好的自调节能力，精确度更高，并行优化后效果更加显著。

我们在前面已经介绍了卷积神经网络和人工免疫算法，卷积神经网络对于网络结构要求很高，通过将人工免疫系统与卷积神经网络相结合，通过对经典卷积神经网络最后一层输出层的改进，并且与现有的卷积神经网络作比较，得到我们的改进卷积神经网络能够同时用于手写体识别和图像识别。这一发现能够为当下处理特定的模式识别，需要设计不同的卷积神经网络架构的缺点，本文介绍的改进卷积神经网络具有网络节点，参数自调节的能力，有效的提高了卷积神经网络的收敛性和准确性。

### 3.1 基于手写体识别的免疫卷积神经网络性能研究

#### 3.1.1 MNIST 手写数字库简介

手写体数字识别是把手写的数字通过扫描方式进入计算机，搭建一个数字识别系统，自动识别数字。本实验用的手写体MNIST数据集<sup>[5]</sup>由NIST Special Database 3 和 Special Database 1组成。NIST数据库采用SD-3作为训练集，而将SD-1作为测试集。但是由于SD-3采集于美国人口调查局员工，而SD-1则采集于美国高中学生。所以SD-3比SD-1容易辨别。为了使得训练结果和测试结果独立于数据集，LeCun综合了这两个数据集的特点，从而形成了包括60000个样例的训练样本集和10000个样例的测试样本集。

这些数字图像已经做过大小归一化并集中到一个固定大小图像。每张图片大小为28x28。本章我们介绍几种典型的算法用于处理手写体识别，并且搭建免疫

卷积神经网络与传统算法做比较。

### 3.1.2 人工神经网络设计与实现

在处理数据量不大的数据库中我们常常采用浅层的机器学习方法就能够取得良好的性能，对于前面提到的手写体识别库，我们拟采用三层神经网络模型，进行训练，并且对影响训练的参数进行分析。

我们的输入图像为 $28 \times 28$ 大小，首先我们需要对图像进行归一化处理，搭建神经网络模型，由于我们的输入图像是 $28 \times 28$ ，故我们搭建神经网络模型第一层有784个神经元，第二层为100个神经元，第三层为10个神经元（输出层10类），由于我们分类的数据是0-9，所以我们这里只要输出层设计为10类就可以了，假如需要分辨更多的字符，我们可以改变输出层的设计。

我们通过第二章的人工神经网络前向传播算法和反向传导算法模型，加入权重衰减的代价函数能够获得更小的分类误差。

### 3.1.3 免疫卷积神经网络设计与实现

经过训练的卷积神经网络的分类过程和多层感知前馈神经网络类似，将要识别的手写体数字图片作为输入样本，然后经过逐层前向传播，直到最后一层输入层输出最后的分类结果。一种典型的用来识别数字的卷积网络是LeNet-5，其结构如图3.1所示。由图可以看出，我们的神经网络输入层是一副图像，LeNet-5共有7层，不包含输入，每层都包含可训练参数（连接权重）。输入图像为 $32 \times 32$ 大小。




图 3.1 LeNet-5 网络模型架构图

输入是一个手写体数字，然后通过第一层卷积层，第一个卷积层是由6个特征图构成的。输入图像是 $32 \times 32$ 大小的，我们第一层卷积卷积核大小是 $5 \times 5$ 。特征

图的大小就是 $28 \times 28$ ，这样为了让所有的特征能够映射到特征图里面。

卷积过后是一个下采样层S2，特征图数量有6个，大小为 $14 \times 14$ 。S2中特征图的每个单元与C1中相对应的 $2 \times 2$ 邻域相连接。S2层每个单元的4个输入进行求和，乘以同一个可训练参数，再加上一个可训练偏置。结果通过sigmoid函数计算。系数小的情况下，我们可以把特征提取看成线性运算，下采样看成是图像模糊化。系数比较大的情况下，根据偏置的大小，下采样可以被看成是有噪声的“或”运算或者“与”运算。




图 3.2 卷积和子采样过程

卷积过程包括：采用可训练的滤波器 $f_x$ 去卷积一个输入的图像，然后加一个偏置 $b_x$ ，得到卷积层 $C_x$ 。子采样过程包括：邻域像素求和降维成一个像素，然后通过标量加权，加偏置，然后通过一个sigmoid激活函数，最终产生一个缩小四倍的特征映射图。

所以卷积运算可以看成是特征平面映射的过程，下采样层可看作是图像模糊化的过程，有二次特征提取的作用。

第三层是一个卷积层，卷积核大小也是 $5 \times 5$ ，这里卷积层和S2层采用不完全连接方式，通过实验得到的特征图大小是 $10 \times 10$ ，特征图数量是16。

第四层是一个下采样层，是由16个 $5 \times 5$ 大小的特征图构成。特征图中的神经元与上一层的4个邻域相连，与C1和S2之间的连接是一样的。

第五层是一个卷积层，有120个特征图。特征图中每个单元与上一层的 $5 \times 5$ 区域相连。S4层特征图大小是 $5 \times 5$ ，所以C5层特征图的大小是 $1 \times 1$ ：这构成了S4和C5之间的全连接。

第六层有84个单元，这个设计与输出层设计有关，与C5层全相连。这个地方采用的网络结构就是上面提到的RBF神经网络的输入层，我们用RBF神经网络作为卷积神经网络输出层，然后通过免疫模式分类算法进行改进，动态调节网络节点，参数和权值。

最后，输出层采用上面说的欧式径向基函数单元组成。我们可以将RBF网络输出理解成衡量输入模式和与RBF相关联类的匹配程度的惩罚项。

本文第二章提出的免疫卷积神经网络算法，通过免疫算法改进卷积神经网络，并且通过数据并行和模型并行，由于卷积神经网络本身就有并行性，能够更好地达到并行化处理效果。



## 3.2 基于小图像识别免疫卷积神经网络性能研究

### 3.2.1 CIFAR-10 简介

CIFAR-10是用于物体识别的既定计算机视觉数据集。它是80000000细小的图像数据集的子集，由60000副32 \* 32的图像组成，包含10个对象类，每类6000副彩色图像，有50000个训练图像和10000的测试图像。

该数据集被分成5个培训批次和一个检验批，每批次是10000副图像。测试批量正好每类中随机选取的1000副图像。培训批次包含在随机顺序剩余图像，但有些培训批次可能含有比另一个类的详细图像。在它们之间，分批培训包含每个班正好5000张图片。对由很多图片构成的一个矩阵进行白化处理，并且需要先进行均值化。我们采样的训练样本在输入到分类器之前，先对其每一维度进行均值化，这样是为了增强每张图片的对比度。图3.3是这些采样的类中的数据集。

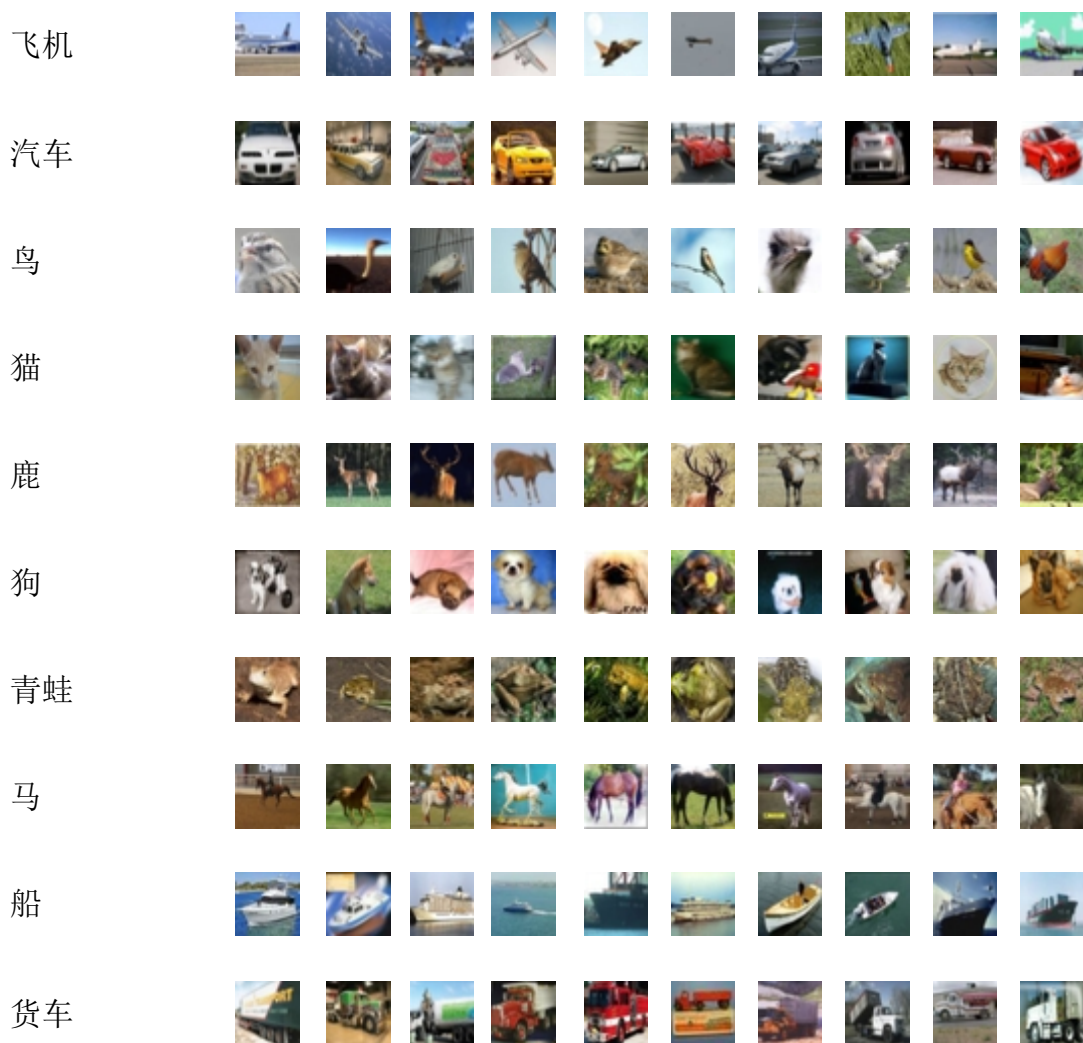


图 3.3 CIFAR-10 的数据集

### 3.2.2 CIFAR-10 免疫卷积神经网络设计与实现

在这一节我们将描述如何训练一个基于自然图像的多层次模型，通过改进卷积神经网络训练结果与经典卷积神经网络识别精度的比较，发现采用第二章中提出的免疫卷积神经网络算法不仅在识别精度上有所提高，并且能够根据所选择样本库的大小，自动调节卷积神经网络的参数，基于小图像数据库CIFAR-10的免疫卷积神经网络模型与传统的卷积神经网络模型有需要改进的地方。首先就是我们的网络节点数有所增加，网络的调整更加复杂，计算时间也会增大，虽然本算法在小图像识别库上取得了81.5%的精确度，相比于经典卷积神经网络算法有所提高。图3.4是免疫卷积神经网络算法在自然图像识别中的网络结构图。是由卷积层，下采样层，非线性变换层，以及改进的输出层组成。本实验我们分别采用经典卷积神经网络和免疫卷积神经网络对图像进行分类识别。训练批次100次，迭代100次，每迭代1000次测试一次，在cifar10中我们的参数可调，我们每迭代200次显示一次，采用GPU模式进行训练。

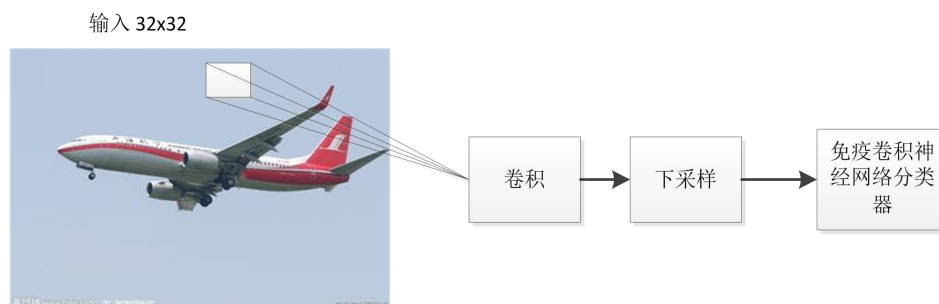


图 3.4 CIFAR-10 免疫卷积神经网络结构图

## 3.3 实验结果

本文实验基于MNIST<sup>[7]</sup>和Cifar-10<sup>[52]</sup>数据库。采用改进的卷积神经网络分别对两个数据库的数据进行测试，并且分别与当前的主流算法分类结果进行比较，最后通过GPU加速并行处理，比较在CPU和GPU模式下面免疫卷积神经网络的性能。

### 3.3.1 基于手写体识别的分类算法性能比较

首先将免疫卷积神经网络用于手写体数字识别中，实验包括两部分，首先用卷积神经网络算法与其它主流算法进行对比，精度如表3-1所示，这里精度来自于<http://yann.lecun.com/exdb/mnist/>.在卷积核参数设置问题上卷积核大小5x5,抽

样层核大小 $2 \times 2$ <sup>[53~55]</sup>。

表 3-1 几种主流分类算法在 MNIST 上分类结果

| 分类器                       | 预处理 | 误分类率 |
|---------------------------|-----|------|
| Linear classifier         | 无   | 12.0 |
| K 近邻算法                    | 无   | 5.0  |
| 采用高斯核的 SVM                | 抗扭曲 | 1.4  |
| 1000RBF+linear classifier | 无   | 3.6  |
| Boosted trees             | 无   | 1.53 |
| LeNet-5                   | 无   | 0.95 |

由表3-1所示，采用简单的线性分类算法精度最低，应用卷积神经网络算法分析取得精度大大高于其他算法，且不需要复杂特征预处理。

下面我们采用前面搭建的神经网络模型对手写体识别，结果如图3.5所示。

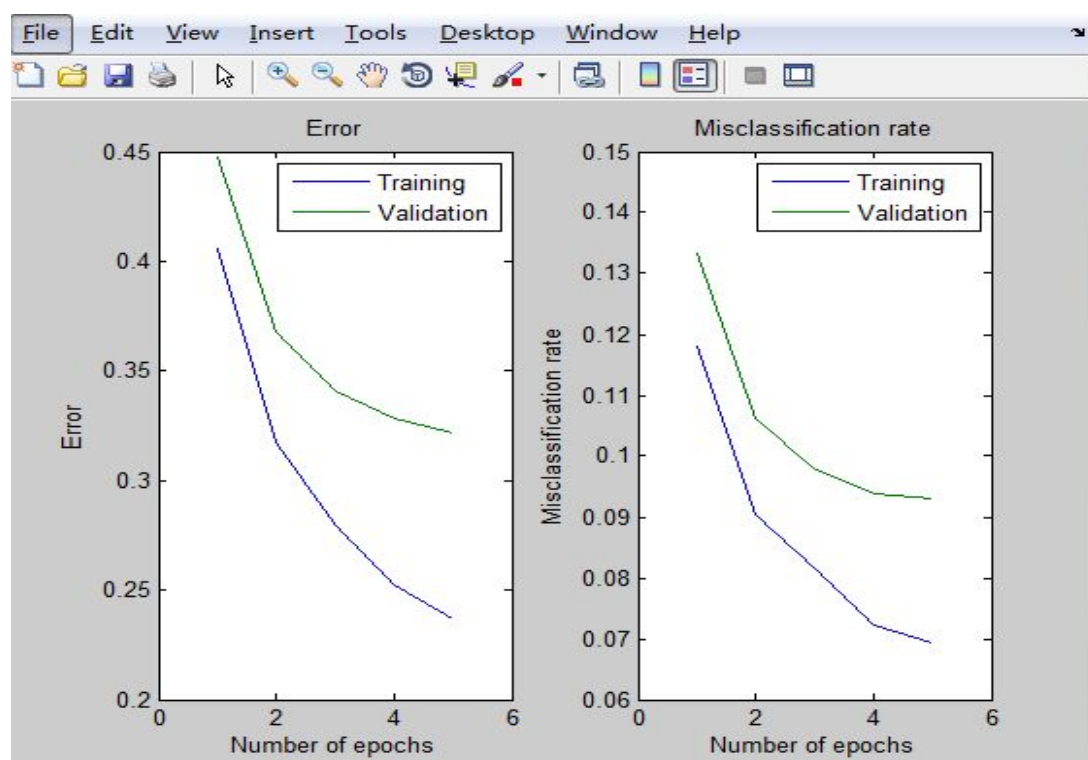


图 3.5 神经网络算法在手写体识别上的识别结果

从上图我们可以看出采用传统线性分类算法搭建神经网络模型在第五次迭代开始，训练的误差率和误分类结果达到稳定，我们采用训练的模型进行分类，分类曲线是图中上面一条曲线，我们可以发现，在第三次迭代开始我们能够取得稳定的分类结果。从图中我们可以看出三层神经网络算法在手写体识别中的误识别率为9.3%。

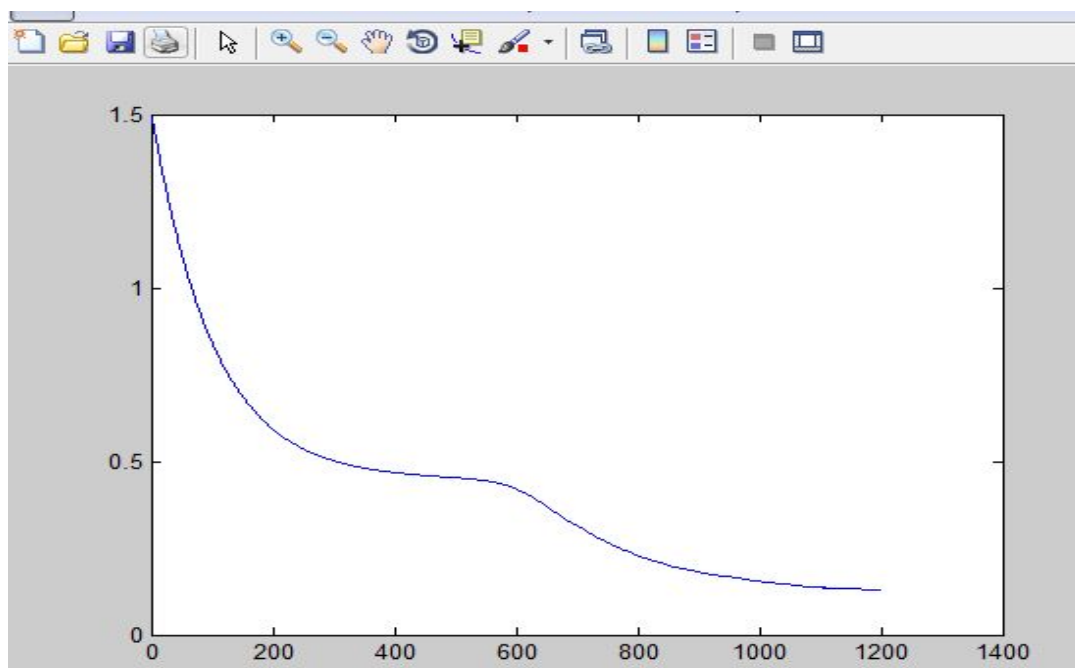


图 3.6 卷积神经网络算法在手写体识别上的识别结果




图 3.7 免疫卷积神经网络算法在手写体识别上的识别结果

图3.6和图3.7的实验结果如表3-2所示，将CNN算法分类结果与改进的免疫改进卷积神经网络(I-CNN)对比<sup>[18]</sup>。

表 3-2 改进卷积神经网络分类结果

| 数据库   | CNN(%) | I-CNN(%) |
|-------|--------|----------|
| MNIST | 0.98   | 0.85     |

表3-2显示采用免疫卷积神经网络算法提高了识别的准确率，并且网络训练的参数可以更好的动态调整，采用随机梯度下降不断改善代价函数，从而动态调整整个网络结构和参数。



下图3.8为免疫卷积神经网络算法和手写体分类识别算法的误分类率对比图。从图中可以看出免疫卷积神经网络能够获得最优的精确度，相比传统识别算法具有更高的性能和应用价值。

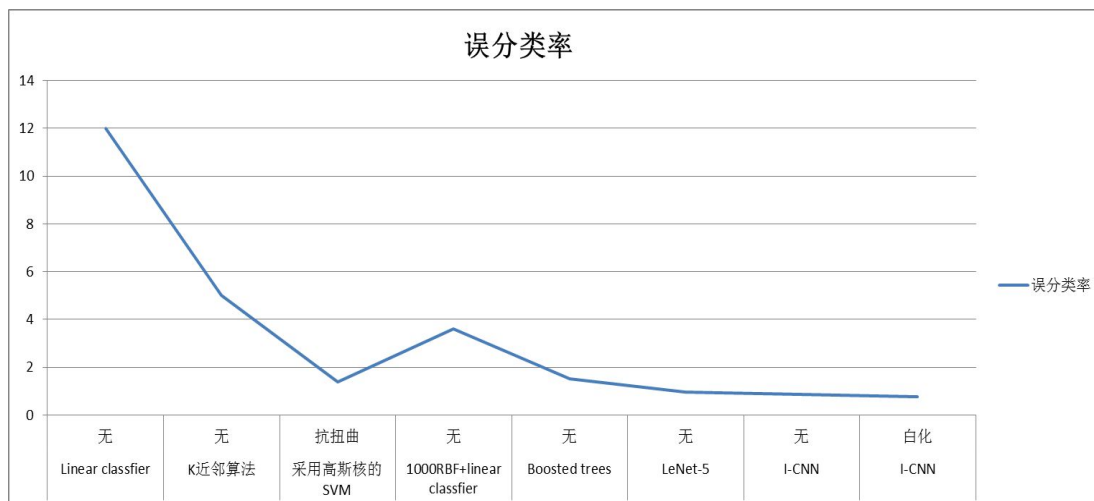


图 3.8 算法在手写体识别上的误分辨率对比图

### 3.3.2 基于小图像识别的分类算法性能比较

免疫卷积神经网络用于自然图像识别中误分类率和经典卷积神经网络比较明显降低。下表是基于小图像识别库的主流算法的误识别率性能。

表 3-3 主流算法小图像分类误识别率

| 分类器    | 误分类率  |
|--------|-------|
| MLP(%) | 59.19 |
| CNN(%) | 33.13 |
| DBN(%) | 30.16 |

从上表可以看出基于小图像识别算法中，卷积神经网络算法能够取得很好的效果，改进的深度信念网络模型也能取得很好的精度，采用第二章提出的免疫卷积神经网络算法构建改进卷积神经网络模型。实验结果如表3-4所示，将CNN算法分类结果与免疫改进的卷积神经网络算法的误识别率作对比。

表 3-4 改进卷积神经网络分类结果

| 数据库   | CNN(%) | I-CNN(%) |
|-------|--------|----------|
| Cifar | 33.13  | 18.4     |

下图3.6为免疫卷积神经网络算法和传统小图像分类识别算法的误分类率比较图。




图 3.9 算法在小图像识别上的误分辨率对比图

从上图我们可以看出采用免疫卷积神经网络算法在小图像识别分类中取得了较好的分类效果。当然，这个分类结果还有很大的改进空间，本文后可以尝试对图像进行白化或者其他预处理（归一化处理），能够使得我们的训练样本具有很强的鲁棒性，在我们构建免疫卷积神经网络模型架构的时候，能够有效的减少我们的训练参数，并且很容易实现并行化，误识别率有所降低。

### 3.3.3 免疫卷积神经网络并行优化结果

实验最后一部分，我们将通过GPU加速并行计算处理的效率和CPU下面处理效率进行对比，发现采用NVIDIA最新推出机器学习加速库cuDNN处理后的DNNs能够获得显著的加速效果。我们通过设置solver\_mode为CPU或者GPU来实现我们加速对比的选择。表3-5是基于手写体数据库和小图像识别库中免疫改进卷积神经网络并行优化时间对比图，从图中我们可以看出对于MNIST手写体库在CPU模式和GPU模式下训练10000次需要的时间分别为854.105秒和47.33秒，对于CIFAR-10在CPU模式和GPU模式下训练5000次需要的时间分别为2800.183秒和108.501秒。

表 3-5 免疫卷积神经网络加速并行优化结果

| 数据库    | MNIST   | CIFAR-10 |
|--------|---------|----------|
| CPU(s) | 854.105 | 2800.183 |
| GPU(s) | 47.33   | 108.501  |

下图是免疫卷积神经网络算法通过GPU加速并行改进后取得的性能加速效果图，从图中我们可以看出免疫改进的卷积神经网络算法，具有良好的并行能力，

在处理大图像，多参数的训练网络中能够取得良好的加速效果。

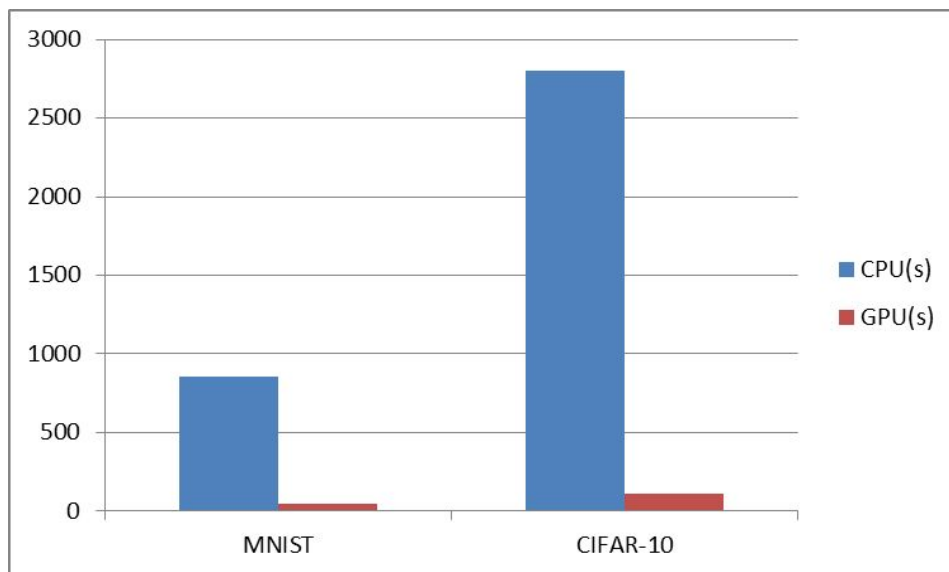


图 3.10 免疫卷积神经网络并行优化效果图

从上面的图中我们可以看出使用NVIDIA的GPU并行加速在传统的CPU 上分别取得了18倍和25倍的加速，使得我们在做大型参数训练的时候取得更好的的效果，并能够有效的减小错误率，能够加快网络收敛速度。

### 3.4 本章小结

本章分别基于手写体识别和小图像识别两个典型的图像识别库做性能研究，手写识别和小图像识别问题国内外已经提出了各种各样的算法研究，当前，LeCun提出的卷积神经网络一直占据领先地位，能够获得很高的准确率，并且收敛性能和训练速度上比其他训练算法更好，本文是在已有卷积神经网络算法的基础上将人工免疫系统与卷积神经网络相结合，通过对输出层RBF函数单元的改进，动态调谐网络参数以及基函数的平滑因子，有效的提高了卷积神经网络的收敛性和准确性。该算法具有数据聚类，参数优化，模式识别等优点。本文提出的免疫卷积神经网络算法在手写体识别和小图像识别上相对于经典卷积神经网络分类算法和其它分类算法具有更好的自调节能力，精确度更高，并行优化后效果更加显著。

如果最后输出层的输入参数过大会降低精确度，并且参数增加，输出层的网络节点数也会增加，网络结构的调整会变复杂，时间复杂度增加。当输入与输出是时间的函数时，结构参数应动态调节。通过观察实验结果，我们得到通过人工免疫网络和神经网络的结合，我们将可能得到一种通用的网络算法用来处理模式识别问题。本文为将来深度学习算法研究提供一个好的方向。

## 第四章 免疫卷积神经网络在嵌入式图像识别应用研究

嵌入式图像识别经过多年的研究和发展,已经取得了不少的研究成果,谷歌眼镜的成功研发象征着图像识别技术在可移动嵌入式设备的巨大飞跃。目前,在我们生活中用于图像识别的系统大多是基于PC架构的,体积大,不易于携带,然而,对于某些特定的场合(如智能家居,户外非布控人员监控等,户外拍照)人们需要一种携带方便,能够自动识别拍摄物的图像识别应用系统,例如,我们出去旅游爬山,往往会看到很多稀有的植物,我们自己都无法认知,那么我们多么希望能有一台相机是可以自动识别我们拍摄的物体的了,本文研究的嵌入式图像识别系统具有很强的现实价值和应用前景。

虽然不少公司推出了图像识别系统,百度,腾讯也开始发力,但是这类图像识别系统还是基于PC架构,其卷积神经网络图像识别算法还是在PC机上面处理的。

嵌入式图像处理系统相对于传统的图像处理系统具有实时性好,便携性好,代码固件化,软件短小精悍,功耗低,抗干扰性强,成本合理等优点。嵌入式图像处理平台也存在着很多不足:硬件方面,市场上处理器的处理速度不够快,内存太小,主频不高等。当下的嵌入式图像处理平台还不能处理过于复杂的算法,否则会使整个平台运行很慢,实时性将会大大降低。

随着现代社会科学技术的不断发展,对于图像处理技术的需求越来越大,对图像处理技术的要求也变得越来越高。嵌入式图像处理技术被用于不同的行业中,来提高本行业产品的质量和生产的效率。因此,对于如何搭建一个用于嵌入式图像处理的平台将会对我们的生活带来新的面貌。

本章首先介绍嵌入式图像识别系统软硬件设计,然后对嵌入式图像识别系统设计中应该注意的问题进行探讨,如嵌入式硬件设备选型,图像样本库的采集与筛选,识别算法等等,这些问题的解决方案直接影响嵌入式识别系统的性能和工作稳定性,最后结合前面提出的免疫卷积神经网络算法在linux操作系统和基于ARM微处理器的S3C6410开发平台上,实现了图像自动检测识别系统。

详细的核心算法设计通过采用免疫卷积神经网络算法作为嵌入式图像识别算子。并且采用逐层可视化的方法论述我们的免疫卷积神经网络模型的具体分类识别过程。最后采用免疫卷积神经网络模型搭建了一个web图像识别的demo,用于处理识别嵌入式系统采集的图像,并最终将识别结果在嵌入式设备上显示。

## 4.1 嵌入式图像识别系统设计

图4.1是基于视频和图像的嵌入式图像识别系统的工作流程，整个系统由基于PC的免疫卷积神经网络图像识别分类器训练和基于嵌入式平台的现场图像识别两部分组成。

目前，由于嵌入式系统的实时性和硬件限制，对于计算量和复杂度相对很高的图像分类器训练算法而言很难满足要求，我们需要从软硬件性能上做出改进。因此图像识别的分类器的训练可在通用PC上完成，由于我们需要的训练样本越大，得到的精确度越高，我们后面采用的样本库是大型图像库ImageNet，最后PC机将训练好的分类器模型文件通过无线网络传输到嵌入式平台。

基于PC的图像识别分类器的训练部分主要由图像样本采集，样本空间管理，特征提取，分类器训练，和分类器性能测试等几个部分组成。

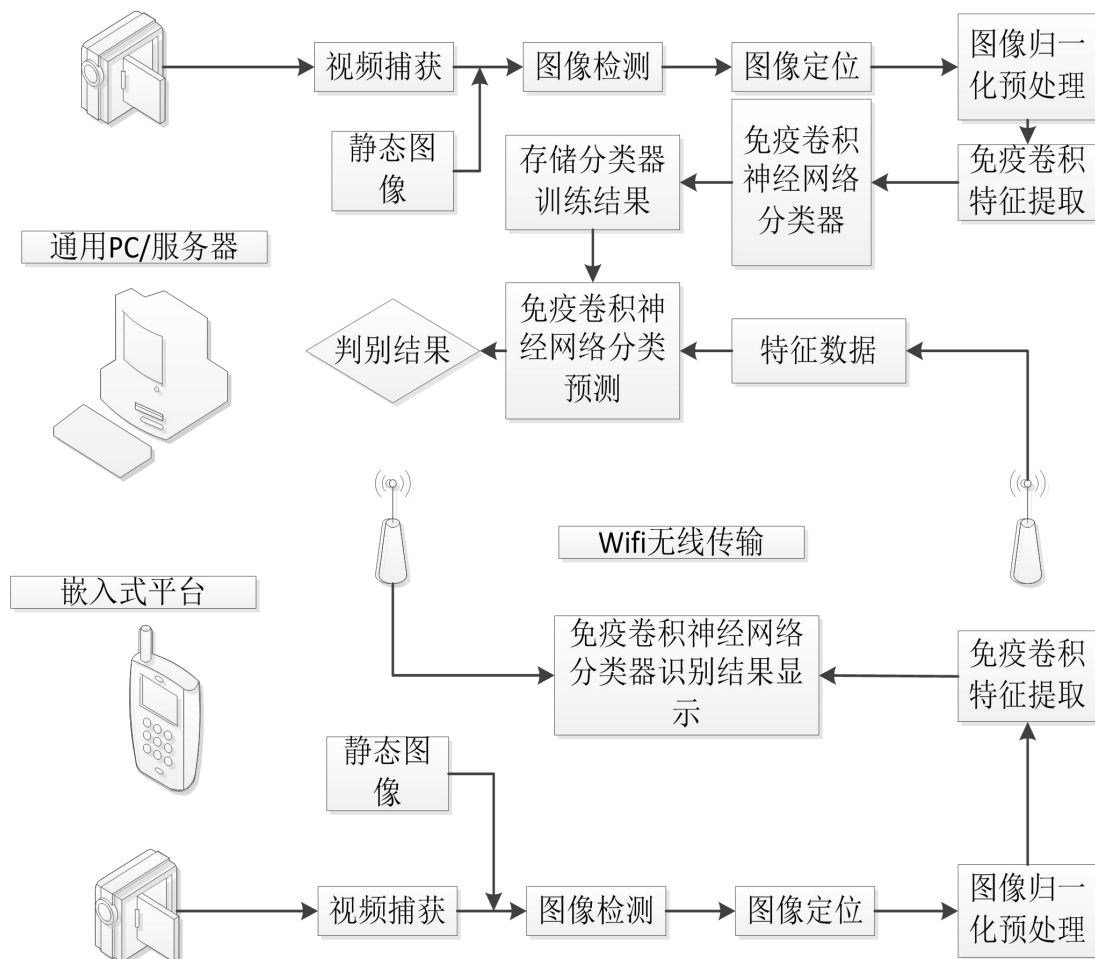


图 4.1 嵌入式图像识别系统设计

嵌入式ARM11处理器模块控制并实时采集各种图像信息，并且通过存储器



模块将采集到的图像信息进行存储，然后通过无线传输模块，将图像信息传输到计算机终端，通过改进卷积神经网络图像识别算法进行识别处理，最后通过WiFi将结果传递给显示模块进行显示，实时的将图像及其处理过程显示给用户。

#### 4.1.1 核心算法的选择

核心算法是图像识别的关键，系统的性能绝大部分由核心算法决定，对于自动图像识别系统而言，核心算法包括图像检测，特征定位与提取以及分类算法等等。各个算法的选择根据实际需要和嵌入式设备的硬件条件决定。对于衡量核心算法的最主要因素有误差率，识别率，识别时间，在识别核心算法时，我们通常需要考虑这些指标<sup>[3]</sup>。

嵌入式实时图像采集系统要考虑到实时性，光照等因素，我们通过前面对于图像识别算法的比较发现卷积神经网络算法可以直接用于识别灰度图像，省略了人工的进行特征提取的过程，并且识别率上也要高于其他算法，我们第二章提出的免疫卷积神经网络算法在第三章基于图像识别方面和其它算法进行性能比对，发现，并行优化后的免疫卷积神经网络获得了更高的准确率和更优的性能，免疫卷积神经网络在小图像识别的准确率高，易于调节，并且具有很高的实时性。最后采用免疫卷积神经网络算法作为嵌入式图像识别算子。

#### 4.1.2 训练集的构建

目前，对于大多数的基于统计学方法的图像识别算法而言，对训练集有较强的依赖性。在构建训练集的时候，为了使得训练基样本分布和我们嵌入式设备采集到的样本分布一致，除了要综合考虑样本对象的种类还有大小因素外，在训练集的构建过程中还需要考虑以下几个因素：

①样本数量：从训练分类器这个方面来看，识别分类器的泛化能力和识别效果的强弱体现在样本的数量的多少；然而样本数量过多会增大图像特征库的容量，从而增加图像识别核心算法的时间和空间复杂度。

②样本性质：训练样本集应尽可能包括图像不同角度的变化，以增加分类器对于图像不同角度下面的泛化能力，对于可以主动迎合图像的采集设备（如手机，相机），可以主动调整相机的不同视角，不同环境设置下的样本；

③样本差异性：很容易理解，如果加入新样本与原样本库中图像相识度达到90%以上，这个样本对样本分类器贡献几乎没有。这点在视频采集中尤为突出，因此我们在进行样本采集的时候需要加入一定的策略。

通过以上三个方面的综合考虑，我们本章将采用现在最大的一个图像识别库

ImageNet, 里面涵盖了现在当前类别最多多样化的样本库, 能够满足我们对野外动植物的识别。后面我们将会详细的介绍我们的样本库和核心算法的设计。

## 4.2 嵌入式硬件系统设计

### 4.2.1 S3C6410 处理器

S3C6410是由三星公司推出的一款RSIC处理器, 低功耗、高性价比是它最大的特点。它是基于ARM11内核 (ARM1176JZF-S)架构的。并且可以广泛的应用于移动电话和车载通信等领域; 在通信服务方面, S3C6410展现出了强大的硬件性能, 内置强大的硬件加速器: 包括视频处理、2D加速、音频处理、显示处理和缩放等; 集成了一MFC(Multi-Format video Codec)支持MPEG4 /H.263/H.264编解码和VC1的解码, 能够提供实时的视频会议以及NRSC和PAL制式的TV输出; 除此之外, 该处理器还内置了一个3D加速器, 可以支持OpenGL ES 1.1/ 2.0和D3DMAPI, 能够实现4M triangles/s的3D加速; 同时, S3C6410还包含了优化的用于通用宽带服务的外部存储器接口。

本文采用的是飞凌公司提供的ARM11学习板, 价格便宜, 并且提供很多的学习资料, 有助于我们完成改进卷积神经网络图像识别算法在嵌入式系统中的应用。下图4.2是S3C6410的实物图。




图 4.2 S3C6410 实物图



## 4.2.2 摄像头采集模块

摄像头我们通过对比传统的CCD摄像头模块和Omni Vision 公司生产的CMOS摄像头OV9650，发现无论是敏感度、功耗，还是分辨率方面CMOS摄像头都展现出来了其强大的图像采集能力。CMOS9650摄像头模块支持ITU-BT 601/6568位模式,可以实现4096\*4096像素点采集。S3C6410处理器提供了一个GPIO信号（GPP14），主要用于对摄像头进行上电控制，并且帮助系统实现电源管理。CMOS摄像头接口设计原理图如图4.3所示。

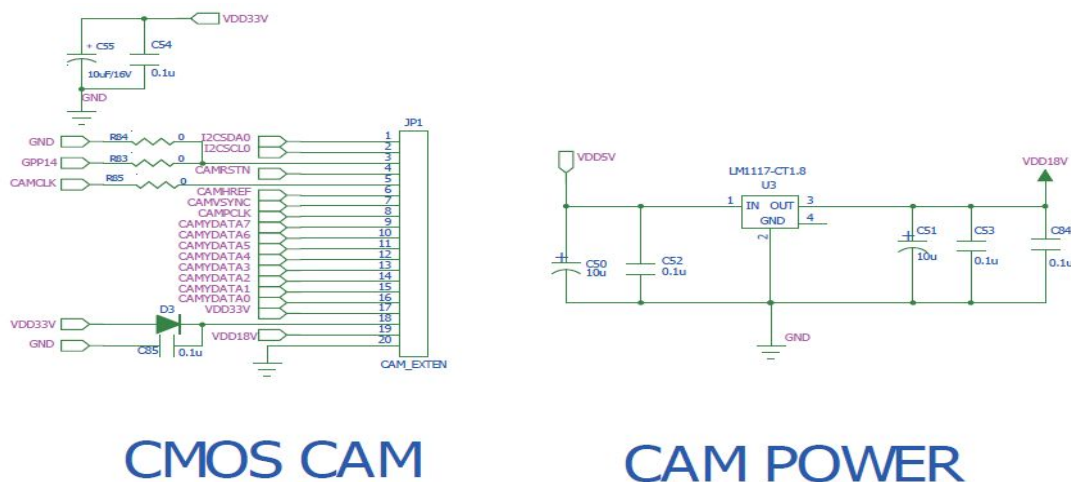


图 4.3 CMOS 摄像头接口设计图

## 4.2.3 WIFI 无线传输模块

OK6410开发板已经提供了外部接口用于外部扩展WIFI模块，这个接口与SDCARD1卡座使用的是同一路信号。我们可以选择厂商提供的和开发板配套的WIFI模块，来实现WIFI上网，无线连接等功能。图4.4为WIFI模块的接口设计图。

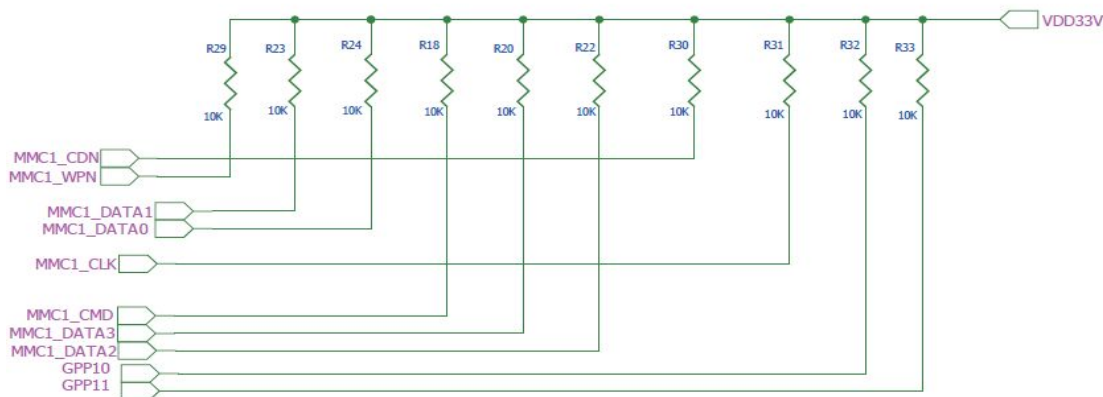


图 4.4 WIFI 模块接口设计图

## 4.3 嵌入式软件系统设计

### 4.3.1 linux 系统移植

Linux操作系统是Unix操作系统的一种克隆系统，它的源码是自由和开放的。是一个基于POSIX标准和Unix标准的多任务、多用户、支持多线程和多CPU的操作系统，用户可以通过网络或其他途径免费获得，并可以进行自主开发。Linux操作系统可以安装在各种计算机平板等硬件平台中。比如手机、台式计算机、平板电脑、服务器、工作站、大型机和超级计算机。本次试验中使用的是Linux2.6.36版本，开发环境是ubuntu。

我们通过一键烧写就可以完成嵌入式平台引导程序uboot移植、内核（zImage）移植和文件系统（Yaffs2 文件系统）烧写。或者当由于各种原因造成的开发板无法启动时，也可以很好地解决问题。鉴于一键烧写更方便快捷，本次实验采用此方法烧写系统。开发板的Nand Flash大小为4G，RAM大小为256M。

### 4.3.2 无线传输系统设计

无线传输系统应用到的就是客户端和服务端之间的交互，这种交互需要网络协议栈进行通信才能实现。当我们编写无线传输网络时，必须说明和显示许多细节，并且要考虑到无线传输网络安全性能层面。注意是服务器还是客户机，是被动等待还是主动通信机制等。进行通信的时候，我们还需要表明我们采用的TCP/IP协议的一些协议，端口绑定，比如发送方要说明传送的是什么数据，接收方要说明接受的数据放在哪里。

TCP是一种可靠的传输服务，因为它主要是为了解决网络的可靠性问题，它通过各种机制来减少错误的概率。在网络状况不是很好的情况下需要使用TCP协议，它可以从一台主机到另一台主机的数据流保证的是不是一个新的重复数据或数据丢失的情况。

基于socket编程的TCP/IP协议，计划用C/S架构，服务器程序和客户端程序，在Linux虚拟机的PC交叉编译环境，将客户端的可执行文件刻录到ARM11开发板编译，摄像头收集的信息到PC指定的通过无线传输模块传送的，如图4.5所示：

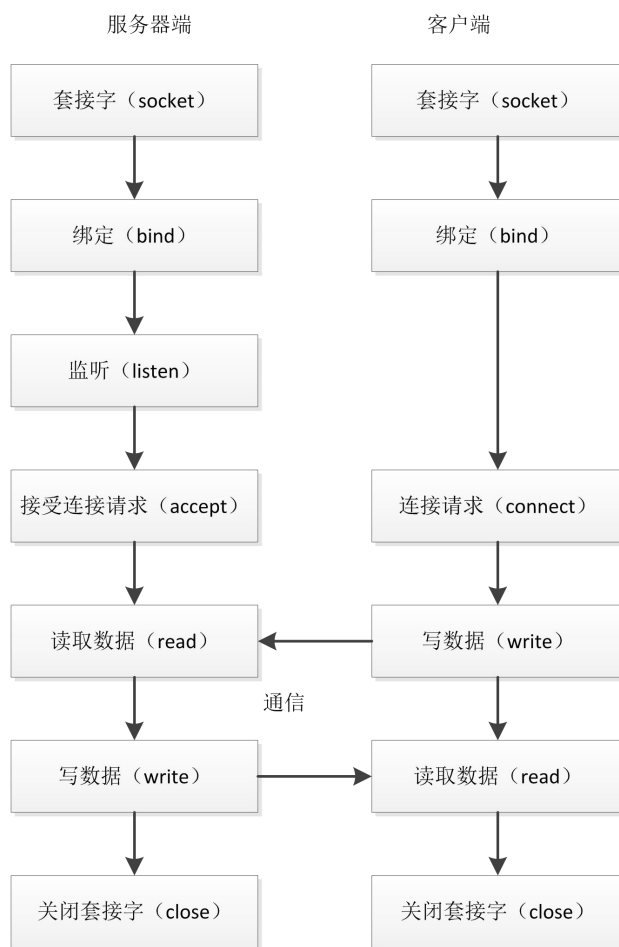


图 4.5 基于 TCP/IP 协议的 socket 网络流程图

本章设计的无线传输系统服务器端程序设计如下，一共包含八步：

- (1) 加载套接字库。
- (2) 创建套接字 (socket)。
- (3) 将套接字绑定 (bind) 在一个本地的地址和端口上。
- (4) 将套接字设为监听模式 (listen)，接收客户请求。
- (5) 等待客户请求到来；当收到请求后，接受连接请求 (accept)，返回一个新的套接字。
- (6) 读取客户端发送的数据 (read)。
- (7) 返回，等待另一客户请求。
- (8) 关闭套接字。

本章设计的无线传输系统客户端程序设计如下，一共包含五步：

- (1) 加载套接字库
- (2) 创建套接字 (socket)。
- (3) 向服务器发出连接请求 (connect)。

- (4) 将需要传送的数据写入缓冲区（write）。
- (5) 关闭套接字。

### 4.3.3 图像采集程序设计

Video4Linux2是Linux系统下的应用编程接口，进行视频音频等应用开发。本章介绍的免疫卷积神经网络算法进行样本训练的样本就是通过这个采集的，然后通过上面的无线传输模块传输到PC机，进行机器学习。在我们的嵌入式系统中，我们把所有的外设看成是特殊文件，我们这里把驱动摄像头的驱动文件称为设备文件。我们要使用摄像头模块，首先需要加载该模块的驱动，然后通过Video4Linux2中提供的函数接口进行图像采集程序的设计。视频图像采集程序流程图如图4.6所示：

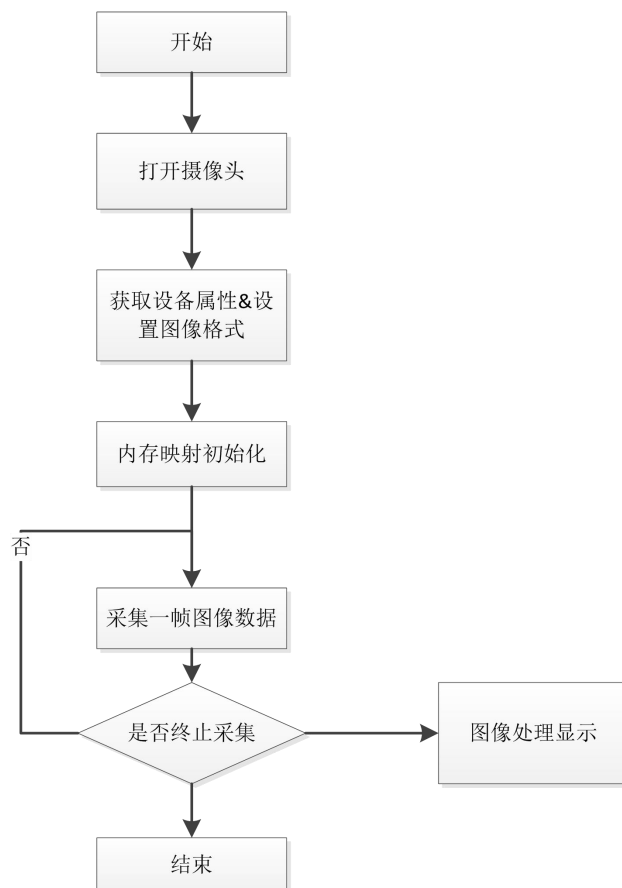


图 4.6 视频图像采集程序流程图

接下来我们将程序在host端通过交叉编译，生成ARM11上可用的可执行文件testcamera用于嵌入式图像采集程序。

然后通过无线传输将该文件拷贝到ARM11开发板，并且执行该文件，下图

4.7为成功搭建嵌入式图像实时采集系统的实物图。




图 4.7 成功搭建嵌入式图像采集系统实物图

#### 4.4 免疫卷积神经网络图像识别

卷积神经网络是多层神经网络，由卷积层和子采样层交替组成，我们用卷积神经网络来模拟视觉神经的简单细胞和复杂系统，用人工免疫系统学的理论来说，可以将这些系统看成是我们的B细胞和T细胞，这样的启发式学习，可以让我们将人工免疫系统和经典卷积神经网络结合起来，处理具体问题。卷积神经网络不同模型的区别之处在于卷积层和子采样层的实现方式和他们的训练方式<sup>[56]</sup>。深度卷积神经网络为了防止出现过拟合，我们需要提供一个大的训练样本，如果样本太少将会过拟合。处理相同的问题时，在数据量多的情况，可以用相对复杂的模型处理问题，在数据量少的情况下，可以用相对简单的模型处理问题。在这个基础上理解论文中的这句话，有足够的数据的时候可以防止模型过拟合。过拟合，当数据量太少时，模型无法完成充分的训练，容易过度拟合的符合少量的训练数据特征，对测试数据效果不好；欠拟合，数据量太多，模型太简单没有充分的利用到数据。本章的模型构建将采用ImageNet项目提供的数据库，下面将讲述为什么要用此数据库并且简单描述本优化深度卷积神经网络模型的构建。



#### 4.4.1 ImageNet 简介

ImageNet是一个持续的研究努力为客户提供世界各地的研究人员易于访问的图像数据库。它是根据WordNet的层次结构组织的图像数据集。WordNet中的每个有意义的概念，可能由多个单词或单词短语描述的，被称为“同义组”或“同义词集”。有超过10万个同义词集WordNet中，其中大部分是名词（80000）。在ImageNet，我们的目标是提供平均1000的图像来说明每一个同义词集。我们希望在WordNet的层次结构中ImageNet将提供数以千万计的图像的大部分概念。该 ImageNet 项目让越来越多的人在图像处理和机器视觉领域手启发，自从数字时代的诞生和网络规模的数据交换的有效性，研究人员在这些领域一直在努力设计出更多，更复杂的算法来索引，检索，整理和注释的多媒体数据。但是，良好的科研需要很好的资源。为了解决大规模这些问题，如果存在一个大型图像数据库将是极大帮助研究人员。这个时候 ImageNet 数据库就诞生了。

#### 4.4.2 免疫卷积层神经网络的构建

对于图像识别问题，2012年Hinton与其学生将深度学习用于ImageNet（图像识别目前最大的数据库）上，并且取得了非常惊人的成绩，它的结果相对原来的最优结果都有较大的提高（前五错误率由25%降低为17%）<sup>[57]</sup>。下图模拟该卷积神经网络模型搭建的免疫卷积神经网络图像识别模型




图 4.8 免疫卷积神经网络结构

本章设计的用嵌入式图像识别系统的免疫卷积神经网络架构一共分为8层，其中前面5层是卷积神经网络，后面的3层是全连接的网络。最后一层是softmax和我们的免疫改进线性输出混合输出决策层。输出节点数是1000，证明可以分类1000中图像。

对于我们提出的免疫卷积神经网络算法要能够成功的用到嵌入式图像识别系统中，还需要做以下改进：

- 1) 采用ReLU函数来代替Tanh函数引入非线性；
- 2) 为了满足实时性的要求，我们在硬件上面改进是采用2块GPU来进行并行计算，减少了时间消耗，在结构上，将不同显卡上面的前后层节点之间不连接，

从而提高训练速度；

3) 对于同层相邻节点的响应进行局部归一化处理，能够提高识别率；

4) 有交叠的pooling；

对于过拟合的问题，我们采用下面两种方式进行改进：

a.数据加强：

对我们的训练样本进行左右对称平移变换，增加训练数据的维度；采用PCA变换构造新样本。

b.Dropout：

Dropout方法是一种启发式学习算法。它的思想就是在我们进行训练的时候，随机的让网络中的某些隐含层节点的权重不工作，不工作节点可以暂时被忽略，但是它的权重还是得保留下来，因为有可能下次样本输入的时候它又得工作了。2012年Hinton提出通过阻止特征检测器的共同作用来提高神经网络的性能中发现了dropout。当不采用预训练网络时，我们并不对权值采用L2范数惩罚，而是在每个隐含节点的权值L2范数上设置一个上限bound。当训练过程中，某个节点不满足bound约束，我们就用该bound值对权值进行一个规范化操作。这样就可以让权值更新一开始的时候有个大的学习率供后面衰减用，并且能够搜索更多的权值空间供后面使用。在模型最后的分类测试阶段，我们尝试使用“均值网络”来得到隐含层的输出。也就是说，在网络前向传播到输出层时，隐含层节点的输出值减半（比如dropout的比例为50%）<sup>[58]</sup>。

下面将在免疫卷积神经网络的基础上进一步的优化，优化后的免疫卷积神经网络更加适合于嵌入式图像识别系统，有更好的鲁棒性。

采用mini-batch SGD算法来优化，每个batch128个样本，momentum = 0.9, weight decay = 0.0005

$$v_{i+1} := 0.9 \bullet v_i - 0.0005 \bullet \varepsilon \bullet w_i - \varepsilon \bullet \left\langle \frac{\partial L}{\partial w} \Big|_{w_i} \right\rangle_{D_i} \quad (4-1)$$

$$w_{i+1} := w_i + v_{i+1} \quad (4-2)$$

输出决策层采用的是softmax函数，这个函数是专门用来解决多分类问题的，它是在逻辑回归的基础上扩张而来的<sup>[59]</sup>。Softmax的代价函数是

$$J(\theta) = -\frac{1}{m} \left[ \sum_{i=1}^m \sum_{j=1}^k 1\{y^{(i)} = j\} \log \frac{e^{\theta_j^T x^{(i)}}}{\sum_{l=1}^k e^{\theta_l^T x^{(i)}}} \right] \quad (4-3)$$

在上面公式中，1{\*}是示性函数，它的运算规则是1{表达式值为真}=1,1{表达式值为假}=0。

下面是对逻辑回归代价函数的推广，我们一般通过在式4.3中增加一个权重



衰减项  $\frac{\lambda}{2} \sum_{i=1}^m \sum_{j=1}^k \theta_{ij}^2$ ，它会对过大的参数进行惩罚。回归代价函数变换如下

$$J(\theta) = -\frac{1}{m} \left[ \sum_{i=1}^m \sum_{j=1}^k 1\{y^{(i)} = j\} \log \frac{e^{\theta_j^T x^{(i)}}}{\sum_{l=1}^k e^{\theta_l^T x^{(i)}}} \right] + \frac{\lambda}{2} \sum_{i=1}^m \sum_{j=1}^k \theta_{ij}^2 \quad (4-4)$$

通过增加了第二项函数就变成了凸函数，这样就防止了优化过程中陷入局部最优解的问题。

本章我们将我们改进的输出层线性回归模型和这边提到的softmax回归模型结合起来，即我们在定义我们的深度神经网络模型架构的时候可以定义为 Multiple loss layers. 它的loss 函数如下

$$E = \frac{1}{2N} \sum_{n=1}^N \| \hat{y}_n - y_n \|_2^2 + \frac{-1}{N} \sum_{n=1}^N \log(\hat{p}_n, I_n) \quad (4-5)$$

#### 4.4.3 逐层可视免疫卷积神经网络

(1) 首先，我们初始化设置我们图片分类的环境。我们选用的图像批次是10个批次，采用最近为原则的图形的插值，免疫卷积神经网络能够直接处理灰度图像。设置我们所需的分类模型，以及训练好的模型。

(2) 接着下表4-1显示各层的参数和形状，第一个是批次，第二个是特征图的数量，第三和第四是每个神经元中图片的长和宽。

表 4-1 图像识别逐层可视免疫卷积神经网络参数

| 网络参数  | 图像批次 | 特征图数量 | 图片维度    |
|-------|------|-------|---------|
| 数据输入  | 10   | 3     | 227x227 |
| 第一层卷积 | 10   | 96    | 55x55   |
| 下采样   | 10   | 96    | 27x27   |
| 第二层卷积 | 10   | 256   | 27x27   |
| 下采样   | 10   | 256   | 13x13   |
| 第三层卷积 | 10   | 384   | 13x13   |
| 第四层卷积 | 10   | 384   | 13x13   |
| 第五层卷积 | 10   | 256   | 13x13   |
| 下采样   | 10   | 256   | 6x6     |
| FC-6  | 10   | 4096  | 1x1     |
| FC-7  | 10   | 4096  | 1x1     |
| 输出层   | 10   | 1000  | 1x1     |

(3) 对我们的图像进行特征提取，我们需要的是BGR图片，所以需要对图片转换颜色频道，最后我们还对图像进行滤波并且查看我们需要分类的图片。



图 4.9 我们要分类的图片

#### (4) 各层的特征

第一个卷积层，一共96个滤波器。通过表4-1我们可以看出来，我们第一个卷积层有96个特征图（即前面说的滤波器），也就是说我们提取出输入图像的96种特征。这就是我们说的卷积特征提取过程，我们从这幅考拉227\*227维度的图片中，通过一个11\*11卷积对图像进行卷积，得到它的一个11\*11样本所具有的特征。

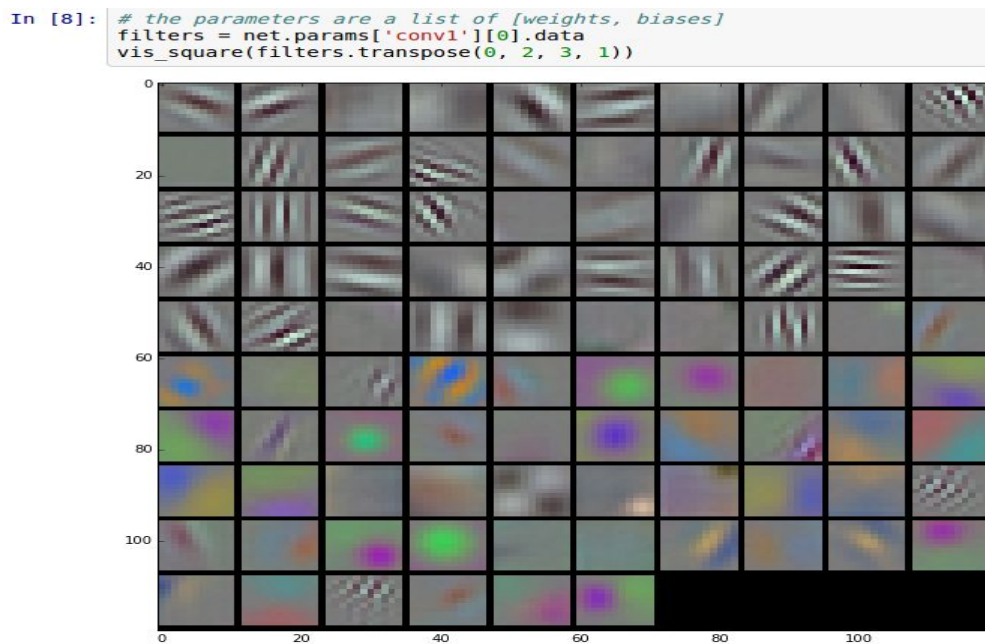


图 4.10 第一层卷积滤波器

卷积层的输出一共96个特征图，我们这边显示前36个，从图中我们可以看出卷积后的图像就是对图像进行模糊化处理，进一步实现边缘检测，特征提取。

```
In [9]: feat = net.blobs['conv1'].data[4, :36]
vis_square(feat, padval=1)
```




图 4.11 第一层过滤后输出

第二个卷积层一共有有256个滤波器，每个特征图的尺寸是5\*5\*48。我们只显示256个滤波器中的前48个滤波器，每个滤波器为一行。这边我们采用的卷积核的大小，以及特征图的数目的确定，是通过免疫卷积神经网络中的自适应，动态调节网络节点和参数的功能确定的。这里我们获得了更多的特征向量，这样也会增加整个网络的计算复杂度。

```
In [10]: filters = net.params['conv2'][0].data
vis_square(filters[:48].reshape(48*2, 5, 5))
```




图 4.12 第二层卷积滤波器

第二层输出256张特征图我们这边也显示前36张，我们可以看出和图4.11相

比更加模糊化，边缘检测提取的特征数量增加。

```
In [11]: feat = net.blobs['conv2'].data[4, :36]
vis_square(feat, padval=1)
```




图 4.13 第二层过滤后输出

接下来的第三，第四和第五层，他们的特征图数目分别为384,384,256。

除了可以观察卷积层以外，我们还可以观察下采样层，前面两个卷积层已经说到，进行卷积特征提取，虽然能有效减少参数个数，但是提取的特征数量依然是百万级的，所以这里我们需要进行下采样处理，通过加权平均的方法，下采样的方法有很多种，这里我们采样的是最大下采样，图4.17为我们第五个下采样层的输入图像。

```
In [15]: feat = net.blobs['pool5'].data[4]
vis_square(feat, padval=1)
```




图 4.14 第五层下采样输入

卷积特征提取结束之后就是我们的三层全连接层，图4.15，图4.16和图4.17



分别是最后三层输出后的直方图分布,从图中我们可以看出第七层之后图的分布没有那么平均了,这种全连接方式其实有点类似于我们神经网络分类模型,第六层我们可以看成是神经网络的输入层的神经元个数,这个个数其实就是输入的参数,也就是我们这里第五层卷积下采样之后的一维特征向量,第七层就是我们神经网络的隐含神经元,最后一层输出层就是我们的分类层,是根据我们需要分类的数目决定的,这里我们用到的库,里面含有1000个类的样本,所以我们可以看到最后直方图的横坐标是1000。




图 4.15 第六层输出直方分布图

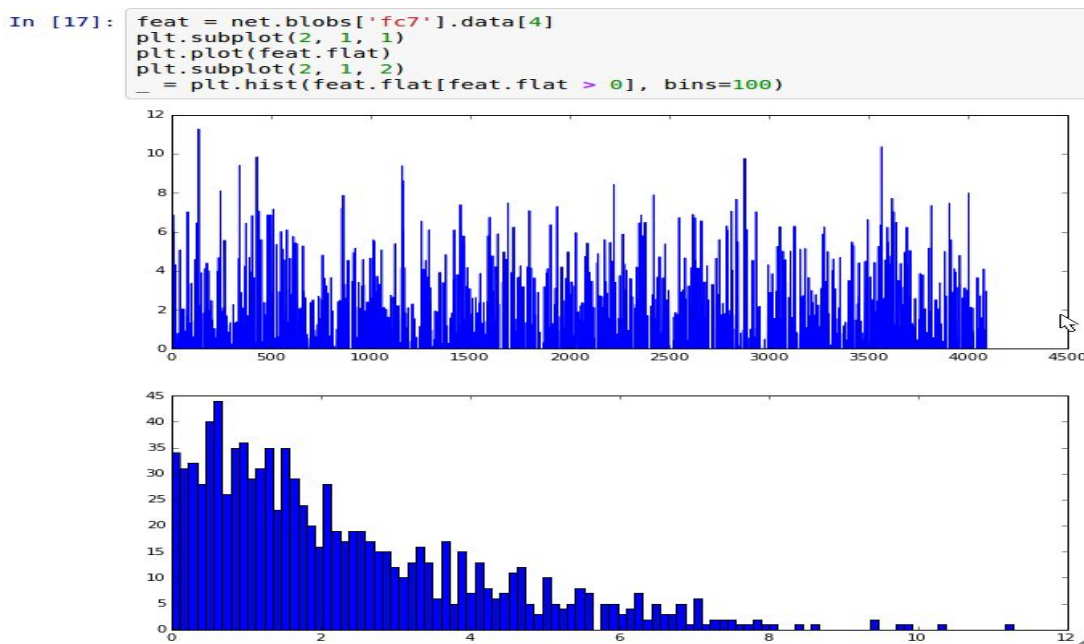


图 4.16 第七层输出直方分布图




图 4.17 最后输出层直方分布图

从图4.17我们可以看出我们线性回归分类最后得到的分类结果是在106，我们输出节点一共是1000，就是说我们采样的训练样本有一千种类别。接下来我们通过有监督学习中定义的标签，来看看此图片经过深度卷积神经网络分类之后所对应的名称，通过图4.18可以发现采用免疫卷积神经网络识别结果是考拉，准确度很高。

```
In [19]: # load labels
imagenet_labels_filename = caffe_root + 'data/ilsvrc12/synset_words.txt'
try:
    labels = np.loadtxt(imagenet_labels_filename, str, delimiter='\t')
except:
    !../data/ilsvrc12/get_ilsvrc_aux.sh
    labels = np.loadtxt(imagenet_labels_filename, str, delimiter='\t')

# sort top k predictions from softmax output
top_k = net.blobs['prob'].data[4].flatten().argsort()[-1:-6:-1]
print labels[top_k]
```

```
[ 'n01882714 koala, koala bear, kangaroo bear, native bear, Phascolarctos cinereus'
'n02497673 Madagascar cat, ring-tailed lemur, Lemur catta'
'n02437616 llama' 'n02493509 titi, titi monkey'
'n02138441 meerkat, mierkat']
```

图 4.18 图像分类结果



## 4.5 实验结果

本章将采用前面所描述的嵌入式图像采集无线传输技术以及经过第三章免疫改进的卷积神经网络图像识别技术结合，从而实验我们本章的主题，实现优化的卷积神经网络在嵌入式系统中的应用。从前面的逐层可视化和最后的分类结果我们已经看到本深度卷积神经网络能够取得良好的模式识别效果，并且具有良好的收敛性。接下来我们将介绍在获得同样的分类结果的基础上，我们采用GPU加速比CPU能够获得显著的效果，更能够满足我们嵌入式系统实时性的需求。

1) 首先我们采用CPU模式进行分类测试，默认是10种预测，裁剪照片的中心和边角，以及去掉他们的镜像版本，还有他们预测的均值。第一种默认方法中，我们可以输入任何大小的图像，我们改进的训练网络可以自动的调节。

2) 我们采用GPU模式进行分类，我们加入预处理，就是把照片的形状变成(256,256)同时进行过采样。

接下来我们对图4.19所示图片进行分类：

```
In [4]: input_image = caffe.io.load_image(IMAGE_FILE)
        plt.imshow(input_image)

Out[4]: <matplotlib.image.AxesImage at 0x7f6658c3da50>
```




图 4.19 分类图片

我们将采用前面训练好的深度卷积神经网络模型，图4.20分别为采用CPU和GPU模式的分类直方图。

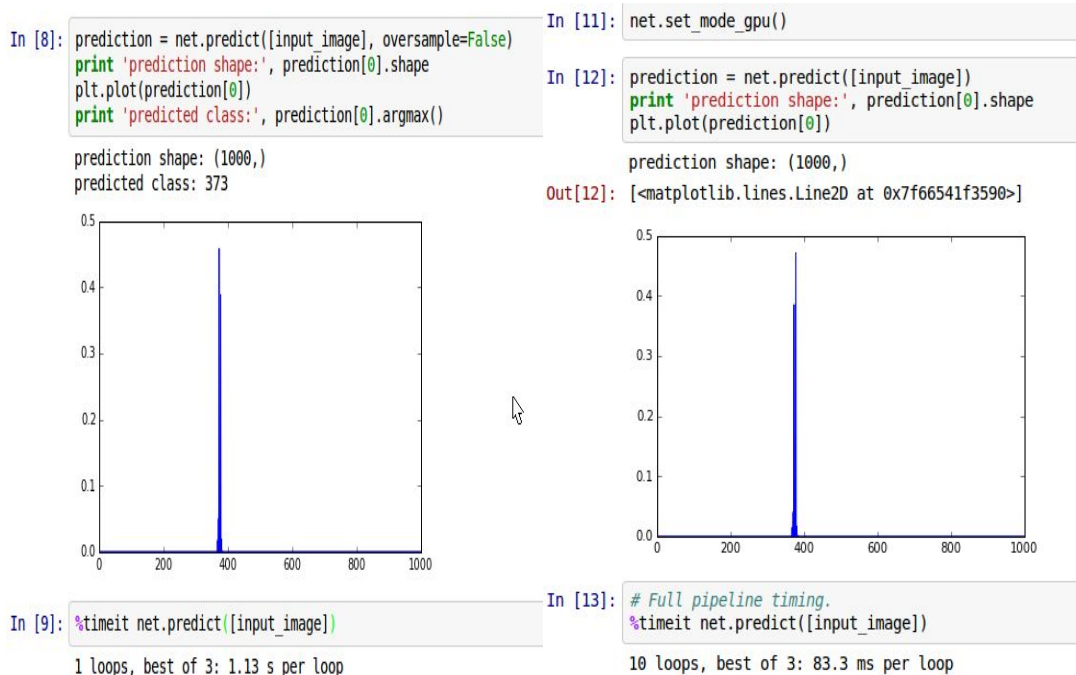


图 4.20 CPU 模式和 GPU 模式下分类结果

从图4.20我们可以看出，我们的分类结果准确率较高，并且我们采用GPU加速并行计算，速度提升了125倍以上，这样显著的加速效果也将为我们实现此图像识别算法应用在嵌入式系统的可行性。现实生活中，移动设备不断增加，拍照也成为我们生活中不可缺少的一部分，本文将立足于可移动嵌入式设备，如手机，摄像机，监控等等电子设备。提供一种自动识别图像机制，可以实现小区监控，图像识别，科研探索等等应用领域。

图4.21是基于嵌入式系统的图像识别Web设计。本文设计采用人性化设计理念，通过PC端训练的样本库训练模型，采用并行后的免疫卷积神经网络算法并行优化算法进行图像识别，然后通过WiFi无线模块将识别结果传递到嵌入式设备并显示结果。从图中我们可以看出，采用并行优化的免疫卷积神经网络算法分类结果具有很高的准确度，并且耗时1.39s,具有很好的实时性能。

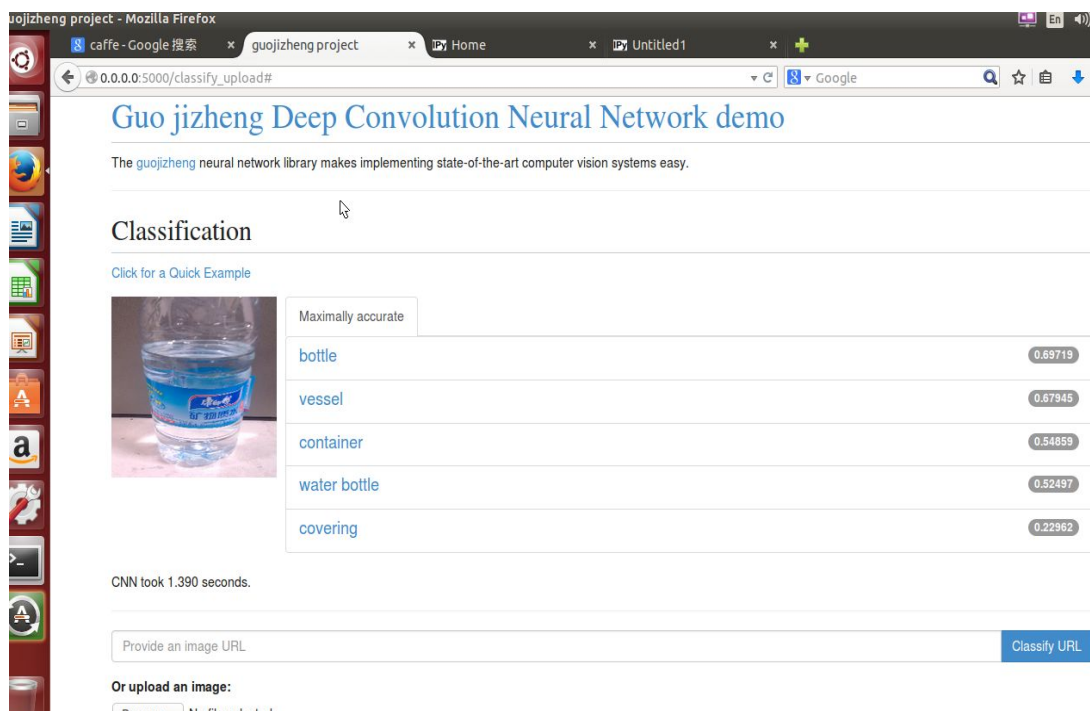


图 4.21 嵌入式图像识别 web 设计

## 4.6 本章小结

我们搭建了更适合图像分类问题的深度卷积神经网络，我们将最后一层输出层的分类器做出改进，使得图像更好的分类。从实验结果来看也取得了良好的识别效果，最后我们通过GPU加速并行计算和CPU模式下面分类所花费时间的对比，发现采用GPU加速后的分类时间取得了显著的加速效果。

由于本章我们的目的是打破复杂算法难以在嵌入式系统中得到应用的瓶颈，通过改进卷积神经网络算法，GPU并行加速，基于改进的卷积神经网络的识别系统，在训练过程中只采用的是采集到的原始的图像，省去了人工特征提取的过程，使得整个系统的实时性和实际可用性大大提高。最终实现优化的卷积神经网络在嵌入式系统中的应用，为我们未来移动机器人，机器视觉领域做出重大贡献。

## 第五章 总结与展望

### 5.1 总结

本文主要研究了人工免疫算法，卷积神经网络，通过人工免疫算法改进RBF神经网络，并且对改进后的算法调整，运用到卷积神经网络的输出层，从而实现卷积神经网络的动态调节，整个网络收敛性更强，能够取得良好的效果。

能够教会机器像人一样思考，一直是科学家长久以来的梦想。深度学习网络架构的出现和发展给这个梦想带来了曙光，虽然还在深度学习研究初期，国内外对于深度学习研究工作的机构并不是很多，但是近几年其在图像, 语音识别, 数据挖掘上取得的突破还是给科学家实现人工智能的梦想带来巨大信心。越来越多的研究机构和互联网巨头争相投入大量的资源进行相关领域的研究工作。对于深度学习的研究进入到了一个快速发展阶段，也取得了良好的效果，但是传统的神经网络算法并不能满足我们的实际需求，越来越多的科学家，开始在结构，算法优化等方面对训练网络做出改进，但是并不能找到一种有效的方法。卷积神经网络是一种经典的深度学习算法，他将特征提取和分类问题相结合，省略了我们人工的进行特征提取的过程。由于卷积神经网络的特殊架构，使得在自身的学习过程中可以对图像的内在信息和规律进行学习，对我们的样本数据有较好的表达能力。本文我们对卷积神经网络做了改进，主要是采用人工免疫网络在处理实际模式识别问题中的优点，动态调节，具有良好的收敛能力，通过人工免疫算法改进卷积神经网络，文中还提出了很多微调的思想，比如文中的dropout层算法，其实是一种启发式的算法，通过文中的结果，我们可以知道，采用人工免疫算法改进的卷积神经网络能够取得良好的识别效果。

神经网络具有很好的自学习能力，并且作为人工智能研究的一部分。那么将其应用到嵌入式系统，将为机器视觉，移动识别带来巨大的突破。所以本文最后将优化的卷积神经网络应用到嵌入式系统，更能够充分体现嵌入式系统的智能特性。采用NVIDIA公司的GPU加速并行计算满足我们嵌入式设备的实时性需求，最后我们图像识别的成功，web demo 的实现都体现了理论和实践的结合。

由于实验条件，以及自我知识的积累不足，实验准备和试验周期短等限制，本文的研究工作还存在一些不足的地方：

(1)在人工神经网络, 人工免疫网络, 卷积神经网络中, 已经存在很多的算法优化用来提高网络的训练速度<sup>[60]</sup>, 优化输出结果和网络权值<sup>[51]</sup>, 自动调整网络结构<sup>[62]</sup>, 离散型免疫模式识别算法<sup>[63]</sup>等等。如果能够将这些方法结合起来, 不仅对卷积神经网络的训练速度上面有一个很大提高, 并且能够提高网络模型最终识别的准确度。

(2)除了每一层滤波器个数对卷积神经网络的训练速度和学习能力有较大的影响外, 还有一些因素也需要注意: 比如我们网络的层次结构深度, 输出层采用的代价函数, 以及采用有效的随机梯度下降算法来快速拟合我们的期望值和实际值, 即使得我们的代价函数最小的参数。这些也需要我们进一步研究。

(3)图像多种多样并且都有自己的特点, 现在卷积神经网络还存在局限, 在二维图像特征提取识别上面能够取得良好的结果, 如果我们可以将实验对象扩展到例如人脸识别, 多物体识别, 行为识别等等, 那么我们将能够更加全面的分析神经网络在嵌入式图像识别任务方面的性能。

## 5.2 展望

人工免疫算法与卷积神经网络结合是一个内容涵盖非常丰富并且在不断发展的领域, 作为在实际问题处理中已经取得良好成果的人工免疫算法, 将其用于优化卷积神经网络是未来我们深度学习的一个重要方向, 具有广泛的应用前景。本文的工作就是通过将人工免疫算法的思想用来优化卷积神经网络的输出层, 研究工作比较初步, 且不够系统和全面, 还存在许多问题需要进一步研究, 充实和完善。并且由于网络的动态调整, 使得网络节点数增加, 网络结构调整起来更加复杂, 计算时间也会增加, 为我们将深度卷积神经网络应用于嵌入式系统的实现增加了难度, 目前我们受限于嵌入式开发板的浮点运算能力, 需要找到一种通用, 高效的图像识别算法。

为了能够构造这样一种通用, 高效, 快速收敛的卷积神经网络, 我们还需要在下面几个方面做出改进:

1) 网络中过滤器的大小能不能通过克隆选择算法, 阴性选择算法, 正常模型人工免疫算法<sup>[64]</sup>, 自动调节, 使得我们搭建的深度卷积神经网络模型能够针对不同的识别对象都具有适应能力, 就像启发式算法一样。

2) 网络层次深度, 对于不同的对象, 我们所设计的卷积神经网络, 隐含层数不一样, 目前都是不断的实验, 人工的去选取一种最好的结构, 虽然在文中也表明针对具体的问题, 也取得了最佳的识别效果, 但是还是限制了网络通用性,



虽然采用文中的人工免疫算法改进卷积神经网络相比于传统的卷积神经网络算法通用性方面有所增强，但还是需要我们进一步的研究出更好的通用网络模型。

3)改进的卷积神经网络算法运算复杂度是制约嵌入式系统应用的主要问题，进一步改进卷积神经网络，结合NVIDIA公司的GPU加速并行计算，来进一步改进卷积神经网络算法来适应嵌入式系统是另一个研究方向。

4) ARM嵌入式系统对运算能力有很大的瓶颈，本文中采用的卷积神经网络的训练过程都是在PC机上进行的，嵌入式ARM通过摄像头采集图像并实时无线传输到PC机，PC机通过训练好的模型对图像进行分类识别。未来研究可以考虑选择针对嵌入式系统硬件加速设备ARM+GPU，实现在嵌入式系统中进行卷积神经网络模式识别。





## 参考文献

- [1]Y Le Cun,U Muller,J Ben,E Cosatto,B Flepp.Off-road obstacle avoidance through end-to-end learning. Advances in Neural Information Processing Systems . 2005.
- [2]Al-Hmouz R,S Challa.Intelligent Stolen Vehicle Detection using Video Sensing. Proceeding of Information,Decision and Control . 2007.
- [3]李外云. 基于 ARM 架构的嵌入式人脸识别技术研究[D].华东师范大学,2008.
- [4]Szarvas Mate,Yoshizawa Akira,Yamamoto Munetaka,Ogata Jun.Pedestrian detection with convolutional neural networks. IEEE Intelligent Vehicles Symposium Proceedings . 2005.
- [5]Lawrence,S,Giles,C.L.,Ah Chung Tsoi,Back,A.D.Face recognition:a convolutional neural-network approach. IEEE Transactions on Neural Networks . 1997.
- [6]Timmis J.Artificial immune system:a novel data analysistechnique inspired by the immune network theory. . 2000.
- [7]LeCun Y,Bottou L,Bengio Y,Haffner P.Gradient-based learning applied to document recognition. Proc.IEEE,1998 . 1998.
- [8]De Castro L N,Von Zuben F J.An immunological ap-proach to initialize centers of radial basis function neuralnetworks. Proceedings of the 5th Brazilian Confe-rence on Neural Networks . 2001.
- [9]JERNEL N J.Towards a network theory of the immune system. Annual Review of Immunology . 1974
- [10]刘建伟,刘媛,罗雄麟. 深度学习研究进展 [J]. 计算机应用研究,2014,07:1921-1930+1942.
- [11]Miroslav Dudík,Zaïd Harchaoui,Jérôme Malick. Lifted coordinate descent for learning with trace-norm regularization.[J]. Journal of Machine Learning Research - Proceedings Track,2012,22.
- [12]李小林. 嵌入式机器视觉技术在雪花牛肉品质检测中的应用研究[D].南京农业大学,2013.
- [13]Tivive,Fok Hing Chi,Bouzerdoum,Abdesselam.An eye feature detector based on convolutional neural network. Proc.8th Int.Symp.Signal Process.Applic . 2005.
- [14]龚涛,蔡自兴.基于正常模型的人工免疫系统及其应用[M].北京:清华大学出版社,2011.
- [15]Li Linhui,Wang Mengmeng,Ding Xinli,Lian Jing,Zong Yunpeng,Fenyuan Wang. Convolutional Neural Network Applied to Traversability Analysis of Vehicles[J]. Advances in Mechanical Engineering,2013,2013.

- [16]Keisuke Korekado,Takashi Morie,Osamu Nomura,Teppei Nakano,Masakazu Matsugu,Atsushi Iwata. Face position detection by a convolutional neural network using an image filtering processor VLSI[J]. International Congress Series,2006,1291:
- [17]Farmer J D,Packard N H,Perelson A S.The immunesystem,adaptation and machine learning. Physica . 1986.
- [18]Payne S J,Arrd HP,Hunt S V,et al.Automated classification and analysis of the calcium response of single Tlymphocytes using a neural network approach. IEEETranstation on Neural Networks . 2005.
- [19]De Castro L N,Timmis J.Aritificial immune systems: a new computational intelligence approach. . 2002.
- [20]Hunt J E,Cooke D E.An adaptive,distributed learningsystem based on the immune system. Proceedings of International Conference on Systems,Man and Cyberne-tics . 1995.
- [21]邓九英,毛宗源,罗英辉. 基于人工免疫网络的模式识别算法[J]. 华南理工大学学报(自然科学版),2008,01:99-104.
- [22]De Castro L N,Von Zuben F J.An immunological ap-proach to initialize centers of radial basis function neuralnetworks. Proceedings of the 5th Brazilian Confe-rence on Neural Networks . 2001.
- [23]郭剑. 基于嵌入式系统的数字图像处理技术的研究[D].西安电子科技大学,2006.
- [24]范晔. 基于免疫机制的神经网络及其应用研究[D].上海交通大学,2008.
- [25]Carter J H. The immune system as a model for pattern recognition and classification.[J]. American Medical Informatics Association. Journal,2000,71.
- [26]Ike E E,Ruddock K H. Visual discrimination of simple geometrical patterns: II. Atypical responses in a subject suffering difficulties with pattern recognition.[J]. Spatial Vision,1987,21.
- [27]叶莲. 基于免疫算法的分类方法及其应用研究[D].重庆大学,2012.
- [28]Razvan-Daniel Albu. Human Face Recognition Using Convolutional Neural Networks[J]. Journal of Electrical and Electronics Engineering,2009,22.
- [29]杨南. 基于神经网络学习的统计机器翻译研究[D].中国科学技术大学,2014.
- [30]邢健飞,罗志增,席旭刚. 基于深度神经网络的实时人脸识别[J]. 杭州电子科技大学学报,2013,06:107-110.
- [31]吕刚,郝平,盛建荣. 一种改进的深度神经网络在小图像分类中的应用研究[J]. 计算机应用与软件,2014,04:182-184+213.
- [32]刘建伟,刘媛,罗雄麟. 深度学习研究进展 [J]. 计算机应用研究,2014,07:1921-1930+1942.
- [33]Evgeny A. Smirnov,Denis M. Timoshenko,Serge N. Andrianov. Comparison of

Regularization Methods for ImageNet Classification with Deep Convolutional Neural Networks[J]. AASRI Procedia,2014,6.

[34]龚涛(导师: 蔡自兴). 免疫计算的建模与鲁棒性分析研究[D]. 长沙: 中南大学博士学位论文, 2007.

[35]龚涛, 蔡自兴. 自然计算的广义映射模型[J]. 计算机科学, 2002, 29(9): 27-29.

[36]蔡自兴, 龚涛. 免疫算法研究的进展[J]. 控制与决策第 19 卷第 8 期, 2004, 841-846.

[37]莫宏伟, 左兴权. 人工免疫系统[M]. 北京: 科学出版社, 2009.1.

[38]Fabien Lauer, Ching Y. Suen, Gerard Bloch. A trainable feature extractor for handwritter digit recognition. Pattern Recognition . 2007

[39]Al-Hmouz R, S Challa. Intelligent Stolen Vehicle Detection using Video Sensing. Proceeding of Information, Decision and Control . 2007.

[40]Tivive, Fok Hing Chi, Bouzerdoun, Abdesselam. An eye feature detector based on convolutional neural network. Proc. 8th Int. Symp. Signal Process. Applic . 2005.

[41]Lawrence, S, Giles, C.L., Ah Chung Tsoi, Back, A.D. Face recognition: a convolutional neural-network approach. IEEE Transactions on Neural Networks . 1997.

[42]Szarvas Mate, Yoshizawa Akira, Yamamoto Munetaka, Ogata Jun. Pedestrian detection with convolutional neural networks. IEEE Intelligent Vehicles Symposium Proceedings . 2005.

[43]Y Le Cun, U Muller, J Ben, E Cosatto, B Flepp. Off-road obstacle avoidance through end-to-end learning. Advances in Neural Information Processing Systems . 2005.

[44]Fabien Lauer, Ching Y. Suen, Gerard Bloch. A trainable feature extractor for handwritter digit recognition. Pattern Recognition . 2007.

[45]Wei Wang, Shangce Gao, Zheng Tang. Improved pattern recognition with complex artificial immune system[J]. Soft Computing, 2009, 1312.

[46]Weixiang Zhao, Cristina E. Davis. A modified artificial immune system based pattern recognition approach—An application to clinical diagnostics[J]. Artificial Intelligence In Medicine, 2011, 521.

[47]龚丁禧. 稀疏自组合时空卷积神经网络动作识别方法及其并行化[D]. 厦门大学, 2014.

[48]Wei Wang, Shangce Gao, Zheng Tang. Improved pattern recognition with complex artificial immune system[J]. Soft Computing, 2009, 1312.

[49]杨南. 基于神经网络学习的统计机器翻译研究[D]. 中国科学技术大学, 2014.

[50]焦李成[等]著. 免疫优化计算、学习与识别[M]. 科学出版社, 2006.

[51]Bo Chen. Agent-based artificial immune system approach for adaptive damage detection in monitoring networks[J]. Journal of Network and Computer Applications, 2010, 336.

- [52]Miroslav Dudík,Zaïd Harchaoui,Jérôme Malick. Lifted coordinate descent for learning with trace-norm regularization.[J]. Journal of Machine Learning Research - Proceedings Track,2012,22.
- [53]徐姗姗. 卷积神经网络的研究与应用[D].南京林业大学,2013.
- [54]陈先昌. 基于卷积神经网络的深度学习算法与应用研究[D].浙江工商大学,2014.
- [55]许可. 卷积神经网络在图像识别上的应用的研究[D].浙江大学,2012.
- [56]Evgeny A. Smirnov,Denis M. Timoshenko,Serge N. Andrianov. Comparison of Regularization Methods for ImageNet Classification with Deep Convolutional Neural Networks[J]. AASRI Procedia,2014,6.
- [57]朱亚男. 基于人工免疫系统的智能融合算法研究及应用[D].中南大学,2012.
- [58]Wei Wang,Shangce Gao,Zheng Tang. Improved pattern recognition with complex artificial immune system[J]. Soft Computing,2009,1312.
- [59]Masakazu Matsugu,Katsuhiko Mori,Yusuke Mitari,Yuji Kaneda. Subject independent facial expression recognition with robust face detection using a convolutional neural network[J]. Neural Networks,2003,165.
- [60]陈硕. 深度学习神经网络在语音识别中的应用研究[D].华南理工大学,2013.
- [61]陆璐. 卷积神经网络的研究及其在车牌识别系统中的应用[D].合肥工业大学,2006.
- [62]Hunt J E,Cooke D E.An adaptive,distributed learningsystem based on the immune system. Proceedings of International Conference on Systems,Man and Cybernetics . 1995.
- [63]邓九英,毛宗源,罗英辉. 基于人工免疫网络的模式识别算法[J]. 华南理工大学学报(自然科学版),2008,01:99-104.
- [64]吕刚,郝平,盛建荣. 一种改进的深度神经网络在小图像分类中的应用研究[J].

## 在校期间主要学术成果

### (1) 发表和录用的论文

[1] Jizheng Guo, Tao Gong, Tiantian Fan, Bharat Bhargava Improved convolution neural network with Immune Algorithm (Immune Computation)

### (2) 专利申请情况

[1]郭吉政,龚涛,安俊峰. 一种可移动嵌入式 WiFi 无线传输系统[P]. 上海: CN203563198U,2014-04-23.

[2]安俊峰,龚涛,卢萌萌,郭吉政. 一种基于 SVM 的大数据分类预测方法[P]. 上海: CN103902706A,2014-07-02.

[3]安俊峰,龚涛,郭吉政. 一种基于 VC++和 tshark 的流量监测和病毒防御方法[P]. 上海: CN103152225A,2013-06-12.

[4]郭吉政,龚涛,安俊峰,裴蕾. 基于太阳能热水器的大棚温湿度控制系统[P]. 上海: CN203232337U,2013-10-09.





## 致谢

本论文的完成离不开我导师龚涛副教授的关心和指导，龚老师治学严谨，认真负责工作态度，让我认识到，学习是一个循序渐进不断积累的过程，论文能够完成离不开一直以来的鼓励还有物力方面的支持。两年半的硕士研究生期间，无论是学术研究，还是生活以及和学生之间的交流，龚老师都给予了悉心照顾和无微不至的关怀，他平易近人，偶尔带点幽默风趣的作风让我们不再局限在师生的关系，让我们能够亦师亦友，让我受益匪浅。龚老师在人工免疫方面渊博的理论知识、深厚的专业功底、严谨的治学态度、忘我的敬业精神、谦虚的优秀品质、丰富的工程实践经验和出色的项目开发能力也为我们学生树立了一面旗帜，是我们学术研究，乃至为人处世的楷模，在此谨向我的导师龚涛副教授表示衷心的感谢和崇高的敬意！

研究生短短两年半的时间，东华大学也让我收获颇丰，在这里我每天都在进步，感谢母校为我们提供这么良好的学习、历练平台。进步的同时也不乏欢声笑语，忘不了信息 122 硕一个团结的班集体，更忘不了实验室融洽的学习氛围，非常感谢在读期间师兄、师姐指导与照顾，师弟、师妹们的协助，他们是李龙、杜常兴、姚磊、曹新学、巩小磊、郭长生、裴蕾、安俊峰、郑华科、龙恺、范甜甜、梁文宇、吴义以及吴宇翔等。尤其要感谢在背后一直默默支持我，理解我，体谅我，帮我修改论文的施轶，没有她的鼓励，我也很难完成这篇论文。

此外，我还要衷心感谢所有对论文提出宝贵意见和建议以及评审论文的老师，教授和专家。